PRIMERA ENTREGA · REPORTE DE LA PRIMERA ETAPA

Evaluación de indicadores de actividad y aptitud física para estimar la severidad del uso problemático de internet en niños y adolescentes mediante aprendizaje automático

> *¿Pueden las mediciones físicas que ya se recolectan de forma rutinaria ayudar a detectar a tiempo el uso problemático de internet en niños y adolescentes?*

Autores:

Katherin A. Camargo Cetina, Juan E. Cardona García, Juan D. Martínez Legarda y Daniel Velasco López

Profesor: Milton Orlando Sarria

Proyecto I de Innovación Tecnológica en Inteligencia Artificial · Maestría en Inteligencia Artificial Aplicada · Universidad Icesi, Cali, Colombia · Octubre de 2026

EL PROYECTO EN CUATRO CIFRAS

7,02 %	**2.736**	**4**	**34**
prevalencia estimada de adicción generalizada a internet (113 estudios, 31 países)	participantes de 5 a 22 años con SII registrado	niveles de severidad: ninguno, leve, moderado y severo	casos severos (1,2 %), cuya escasez condiciona la validación

El proyecto en un minuto

El problema	El uso problemático de internet (PIU) en niños y adolescentes se asocia con problemas de salud mental y de sueño, pero suele detectarse tarde porque su evaluación depende de cuestionarios cuya interpretación requiere valoración profesional.
La idea	Evaluar si los indicadores de actividad y aptitud física, que se recolectan de forma rutinaria y no requieren experticia clínica, junto con variables demográficas básicas, permiten estimar la severidad del PIU, medida mediante el índice de severidad del deterioro (SII).
Los datos	2.736 participantes de 5 a 22 años del Healthy Brain Network.
Cómo	Siguiendo CRISP-DM, se compararán modelos lineales regularizados, ensambles de árboles y máquinas de soporte vectorial bajo tres formulaciones de la variable objetivo ordinal, con validación cruzada anidada, estratificada y repetida. Métrica principal: coeficiente kappa ponderado cuadrático (QWK), complementado con el recall por nivel y la tasa de subestimación de los casos moderados y severos.
Comparaciones	El desempeño se comparará con un modelo de referencia demográfico y con un conjunto que incorpora variables de sueño, funcionamiento global y uso de internet. Además, se analizarán la contribución de las variables mediante valores SHAP y los errores por sexo y grupo de edad.
Resultado esperado	Una evaluación rigurosa del potencial de los indicadores físicos como insumo de un tamizaje temprano y accesible, **no una herramienta diagnóstica**.
Este reporte	Presenta el análisis del problema mediante un árbol de problemas, la revisión del estado del arte, los objetivos, la metodología propuesta y la planeación.

Palabras clave: aprendizaje automático, aptitud física, clasificación ordinal, tamizaje, uso problemático de internet.

Glosario rápido

PIU	Uso problemático de internet (por sus siglas en inglés): patrón de uso que genera dificultades psicológicas, académicas, sociales u ocupacionales; también llamado adicción a internet.	**Validación cruzada anidada**	Una validación interna (para elegir hiperparámetros y ajustes) dentro de cada partición de entrenamiento de una validación externa (para medir el desempeño), de modo que los datos de evaluación no intervienen en el ajuste.
SII	Índice de severidad del deterioro: clasifica la severidad del PIU en cuatro niveles (ninguno, leve, moderado y severo).	**QWK**	Coeficiente kappa ponderado cuadrático: mide la concordancia entre el nivel real y el estimado y penaliza más los errores entre niveles lejanos. Vale 1 si la concordancia es perfecta y 0 si equivale al azar.
PCIAT	Parent-Child Internet Addiction Test: versión parental de 20 ítems del Internet Addiction Test (IAT) de Young; de su puntaje total se deriva el SII.	**Recall por nivel**	Proporción de participantes de cada nivel a los que el modelo asigna ese nivel.
Healthy Brain Network	Biobanco de acceso abierto con información psiquiátrica, conductual, de estilo de vida y de actigrafía de niños y adolescentes.	**Tasa de subestimación**	Proporción de participantes con SII moderado o severo a los que se asigna un nivel inferior al real.
Actigrafía	Registro de la actividad física mediante un acelerómetro de pulsera.	**SHAP**	Valores que descomponen cada estimación de un modelo en aportes aditivos por variable.
Tamizaje	Identificación inicial de quienes podrían tener el problema, para priorizar a quienes requieren una valoración especializada. No reemplaza la evaluación clínica.	**CRISP-DM**	Metodología que organiza un proyecto de minería de datos en seis fases iterativas.
Fuga de información	Uso, al entrenar o evaluar, de información que determina directamente la variable objetivo; produce estimaciones de desempeño irreales.	**Metaanálisis**	Estudio que reúne de forma sistemática los estudios publicados sobre una misma pregunta y combina sus resultados con métodos estadísticos para obtener una estimación global. No recoge datos nuevos.

1 El problema y por qué importa

Introducción: contexto, estado del arte, problema, árbol de problemas, objetivos y ética

1.1 Contexto y justificación

EN POCAS PALABRAS

El PIU es frecuente, tiene consecuencias documentadas y se puede intervenir; el reto es detectarlo a tiempo.

¿Qué es el PIU?

El uso problemático de internet (PIU, por sus siglas en inglés) se define como un patrón de uso de internet que genera dificultades psicológicas, académicas, sociales u ocupacionales en la vida de una persona, y en la literatura también se denomina adicción a internet, término que suele emplearse de manera intercambiable [1].

> **No es cuestión de horas conectado.** A diferencia del tiempo de conexión, que por sí solo no define el problema, el PIU se caracteriza por el deterioro funcional: el uso de internet comienza a desplazar el rendimiento escolar, las relaciones familiares, el sueño y otras actividades cotidianas.

Un problema frecuente

Un metaanálisis de 113 estudios epidemiológicos, con 693.306 participantes de 31 países, estimó una prevalencia de adicción generalizada a internet de **7,02 %** (intervalo de confianza del 95 %: 6,09 %–8,08 %), con una tendencia creciente en el tiempo y variaciones importantes según el instrumento de evaluación utilizado [2].

Los niños y adolescentes constituyen una población especialmente relevante, debido a que el uso de dispositivos digitales forma parte de su vida cotidiana desde edades tempranas y a que las consecuencias del problema se presentan en una etapa crítica del desarrollo.

Con consecuencias documentadas

Un metaanálisis de 33 estudios con 303.243 adolescentes encontró correlaciones positivas entre la adicción a internet y [1]:

0,391	**0,318**	**0,264**	**0,252**
Agresividad	Depresión	Conducta suicida	Ansiedad

El coeficiente de correlación r va de −1 a 1: 0 indica ausencia de relación lineal y los extremos, una relación lineal perfecta. Valores entre 0,2 y 0,4 suelen considerarse débiles a moderados.

El sueño también se ve afectado: una revisión sistemática reportó una asociación negativa entre el PIU y el sueño de los adolescentes en todos los estudios incluidos [3], y un metaanálisis con 253.904 adolescentes encontró que el uso excesivo de tecnología se asocia con problemas de sueño (razón de probabilidades, OR = 1,33) y con una menor duración del sueño [4].

> **Importante:** aunque la mayoría de estos estudios son transversales y no permiten establecer relaciones causales [1], la consistencia de las asociaciones justifica la necesidad de identificar el problema a tiempo.

¿Por qué niños y adolescentes? Lo que sugiere el desarrollo cerebral

La literatura sobre el desarrollo cerebral ofrece una explicación posible, aunque no concluyente, de la vulnerabilidad de esta población.

LO QUE APUNTA A UNA MAYOR VULNERABILIDAD

- Durante la adolescencia, los sistemas subcorticales implicados en el procesamiento de las recompensas maduran antes que los sistemas prefrontales de control: hay mayor respuesta a los incentivos mientras el control de los impulsos sigue siendo inmaduro [5], [6].
- En un estudio con resonancia magnética funcional, la activación del núcleo accumbens (región asociada al procesamiento de recompensas) ante recompensas monetarias fue mayor en adolescentes que en niños y adultos [7].
- Esa misma región se activa cuando los adolescentes ven sus propias fotografías con muchos «me gusta» en una red social simulada [8].
- En un seguimiento de tres años, los adolescentes que revisaban sus redes sociales de forma habitual mostraron una sensibilidad creciente a la anticipación de la retroalimentación social [9].
- Un metaanálisis encontró que la adicción a internet disminuye con la edad dentro de la adolescencia [10].

LOS LÍMITES DE ESA EVIDENCIA

- La respuesta del núcleo accumbens a los «me gusta» aumentó con la edad en estudiantes de secundaria, pero no en universitarios, de modo que la sensibilidad a la recompensa social no sigue un patrón simple con la edad [11].
- La adicción a internet también es frecuente en adultos jóvenes [12].
- Aún no se ha establecido si la sensibilidad a las recompensas sociales es propia de la adolescencia o se mantiene en la adultez [13].
- Los estudios longitudinales no permiten determinar si las diferencias cerebrales anteceden al uso habitual o son su consecuencia [9].

Por eso, esta evidencia se presenta como contexto que justifica la atención a niños y adolescentes, y no como una hipótesis que el proyecto pueda contrastar, ya que los datos disponibles no incluyen medidas cerebrales.

Se puede intervenir, pero detectarlo no es sencillo

La detección temprana es relevante porque el PIU es susceptible de intervención. Un metaanálisis de estudios con adolescentes mostró que las intervenciones basadas en ejercicio físico reducen significativamente los puntajes de adicción a internet (diferencia de medias estandarizada, SMD = −1,11) [14].

Sin embargo, identificar a quienes requieren estas intervenciones no es sencillo. La evaluación del PIU se apoya en cuestionarios estandarizados, respondidos por los participantes o por sus padres, cuya interpretación y seguimiento clínico requieren valoración profesional. Esto crea barreras de acceso, culturales y lingüísticas para muchas familias, y hace que con frecuencia el problema no se mida directamente [15].

La propuesta del Child Mind Institute

Frente a esta limitación, el Child Mind Institute propuso explorar si los indicadores de actividad y aptitud física —fáciles de obtener, ampliamente recolectados y que no requieren experticia clínica— pueden servir como aproximación para identificar el PIU. La premisa: el uso excesivo de tecnología se acompaña de cambios en los hábitos físicos, como la reducción de la actividad física [15].

En esa línea, un estudio con 31.954 adolescentes encontró que quienes combinaban baja actividad física y alto sedentarismo frente a pantallas tenían **casi el doble de probabilidad** de presentar adicción a internet [16].

Para estudiar esta posibilidad se dispone de los datos del Healthy Brain Network, un biobanco de acceso abierto con información psiquiátrica, conductual, de estilo de vida y de actigrafía de niños y adolescentes [17]. Una parte de estos datos, correspondiente a participantes de 5 a 22 años, se publicó sin identificar a los participantes en una competencia de Kaggle [15].

Nota sobre el nombre de la población: aunque la muestra incluye adultos jóvenes de 18 a 22 años, en este documento se emplea la denominación «niños y adolescentes», que corresponde a la mayoría de los participantes y a la utilizada por el Healthy Brain Network [17].

¿Cómo se mide la severidad? El SII

En estos datos, la severidad del PIU se expresa mediante el índice de severidad del deterioro (SII, por sus siglas en inglés), derivado del puntaje total del Parent-Child Internet Addiction Test (PCIAT), una versión parental de 20 ítems del Internet Addiction Test (IAT) de Young. El SII clasifica a cada participante en cuatro niveles según su puntaje total, entre 0 y 100 [15]:

Ninguno	Leve	Moderado	Severo
0–30 puntos · SII = 0	31–49 puntos · SII = 1	50–79 puntos · SII = 2	80–100 puntos · SII = 3

El presente proyecto evalúa si las medidas físicas disponibles permiten estimar este índice como apoyo a la detección temprana del PIU.

1.2 Estado del arte

EN POCAS PALABRAS

La literatura sobre PIU y aprendizaje automático se centra en predictores psicológicos y objetivos binarios, y la evidencia sobre los indicadores físicos es contradictoria. Ese es el vacío que aborda el proyecto.

La revisión de la literatura se organizó en tres frentes: la medición del PIU, la evidencia sobre su relación con la actividad física y los enfoques de aprendizaje automático aplicados al problema.

A. Medición del PIU: la primera dificultad es que no hay una medida de referencia consolidada

- Una revisión crítica identificó 45 instrumentos para evaluar la adicción a internet y concluyó que la mayoría requiere trabajo adicional de validación [18].
- El IAT de Young, uno de los más utilizados y base del PCIAT empleado en este proyecto, no mide un constructo único: un análisis factorial confirmatorio identificó en él tres dimensiones distintas [19].
- Esta heterogeneidad tiene consecuencias cuantificables: las estimaciones de prevalencia varían según la escala empleada [2].
- Tras la competencia que dio origen a los datos utilizados, el Child Mind Institute concluyó que las definiciones y evaluaciones clínicas actuales del PIU no se corresponden con precisión con la salud general ni producen conclusiones generalizables entre poblaciones [20].

Implicación para el proyecto: en un problema de aprendizaje supervisado, esto significa que la variable objetivo contiene ruido de medición que limita el desempeño alcanzable por cualquier modelo.

B. Relación con la actividad física: respaldo, aunque no concluyente

- **A favor.** Estudios transversales con adolescentes reportan que la baja actividad física combinada con sedentarismo frente a pantallas se asocia con mayor probabilidad de adicción a internet [16], y que no cumplir las recomendaciones de actividad física, sedentarismo y sueño se relaciona con el problema [21].
- **En discusión.** Un metaanálisis sobre actividad física y adicción al teléfono móvil encontró una correlación moderada en el conjunto de adolescentes y adultos jóvenes ($r = -0{,}243$), pero no significativa en el subgrupo de adolescentes ($r = -0{,}129$; $p = 0{,}24$) [22].
- **El antecedente más directo** proviene de la misma población del Healthy Brain Network: Restrepo et al. encontraron que el PIU se asoció con depresión, trastorno por déficit de atención con hiperactividad, deterioro funcional y alteraciones del sueño, pero no con la actividad física ni con el índice de masa corporal una vez ajustados los factores de confusión [23].
- **Limitación.** La mayor parte de esta evidencia proviene de diseños transversales y de actividad física autorreportada, lo que impide establecer la dirección de la relación.

C. Enfoques de aprendizaje automático: psicológicos, binarios y centrados en una métrica agregada

- **Predicen con variables psicológicas.** Ioannidis et al. utilizaron medidas de impulsividad y compulsividad, obtuvieron un área bajo la curva ROC de 0,83 con regresión logística y de 0,84 con bosques aleatorios (Random Forest), y mostraron una transferencia robusta de los modelos entre sitios de estudio [24].
- **Convierten el objetivo en binario.** Dicotomizan el objetivo mediante un punto de corte del IAT y abordan el problema como clasificación binaria [24], [25]; en un estudio longitudinal con 8.824 escolares, un modelo de árboles extremadamente aleatorizados (Extra Trees) interpretado con SHAP obtuvo el mejor desempeño entre seis algoritmos [25].
- **La excepción: los trabajos con el Healthy Brain Network**, que estiman directamente el SII. Uno de ellos comparó modelos de *gradient boosting* y ensambles con optimización bayesiana, y reportó un QWK de 0,72 con XGBoost [26].
  - Este resultado debe interpretarse con cautela: los hiperparámetros se optimizaron maximizando el mismo QWK de validación cruzada con el que se reporta el desempeño; el trabajo no analiza la posible fuga de información; y no reporta métricas por nivel de severidad, aunque la diferencia entre su exactitud (81 %) y su F1 macro (0,43) sugiere un desempeño bajo en los niveles minoritarios.
- **Técnicas con respaldo metodológico.** En una comparación amplia, los modelos de ensamble basados en árboles superaron a las redes neuronales profundas en datos tabulares de tamaño medio [27], como los disponibles para este problema. Para objetivos ordinales como el SII, Frank y Hall propusieron descomponer el problema en clasificadores binarios que respetan el orden de las clases, lo que permite emplear cualquier clasificador estándar [28].

SÍNTESIS: EL VACÍO Y NUESTRO APORTE

El vacío. La literatura de aprendizaje automático sobre el PIU se basa principalmente en predictores psicológicos y objetivos binarios, mientras que los trabajos con el dataset del Healthy Brain Network, como [26], se centran en maximizar una métrica agregada, con poca atención al desbalance entre niveles de severidad, a la validez de la evaluación y a la generalización. Al mismo tiempo, la evidencia clínica sobre la relación entre indicadores físicos y PIU es contradictoria.

Nuestro aporte. Evaluar de forma rigurosa cuánta información sobre la severidad del PIU aportan las medidas físicas: modelando la severidad como variable ordinal, comparando modelos lineales regularizados, modelos de ensamble y máquinas de soporte vectorial, y analizando de forma explícita el desempeño por nivel de severidad y los alcances de las conclusiones.

1.3 Identificación del problema

EN POCAS PALABRAS

Un tamizaje de primer nivel basado en mediciones físicas podría responder a las necesidades de cinco actores, siempre que reporte su desempeño por nivel de severidad y sea interpretable.

La detección del PIU involucra a varios actores cuyas necesidades condicionan cualquier solución. La Tabla 1 resume las partes interesadas y lo que cada una requiere de un mecanismo de identificación.

Tabla 1. Partes interesadas y necesidades frente a la detección del PIU

Parte interesada	Necesidad
Niños y adolescentes	Ser identificados a tiempo, antes de que el hábito se consolide, mediante procedimientos no invasivos y que no generen estigmatización.
Padres y familias	Contar con señales de alerta accesibles y con orientación sobre cuándo buscar una evaluación especializada, sin depender exclusivamente del acceso a un profesional.
Profesionales de salud mental	Priorizar los casos que requieren evaluación completa, dado que esta es costosa y los recursos especializados son limitados.
Instituciones educativas y servicios de atención primaria	Aprovechar mediciones que ya realizan de forma rutinaria, como las evaluaciones físicas, para identificar riesgo sin requerir experticia clínica.

Parte interesada	Necesidad
Comunidad científica	Disponer de evidencia sobre el valor predictivo de los indicadores físicos y sobre los alcances de los modelos construidos con ellos.

Cuatro limitaciones del enfoque actual

1. **Depende de profesionales.** Aunque el tamizaje del PIU se basa en cuestionarios, su interpretación y la evaluación posterior requieren valoración profesional, lo que impone barreras de acceso, culturales y lingüísticas, y hace que con frecuencia el problema no se mida directamente [15].
2. **No hay una referencia consolidada.** El resultado de la evaluación depende del instrumento empleado [2], [18], [19].
3. **Depende de la percepción de los padres.** El instrumento utilizado en este proyecto depende del reporte de los padres, de modo que la severidad registrada refleja la percepción de un informante externo y no una observación directa de la conducta.
4. **Las alternativas físicas aún no tienen respaldo suficiente.** La evidencia sobre su relación con el PIU es contradictoria [16], [22], [23].

La propuesta: un tamizaje de primer nivel

En este escenario, un modelo de aprendizaje automático entrenado con indicadores físicos podría atender las necesidades identificadas al funcionar como un tamizaje de primer nivel. **Su propósito no sería reemplazar la evaluación clínica**, sino estimar el nivel de severidad a partir de mediciones accesibles para priorizar a quienes requieren una valoración especializada. Así:

- permitiría identificar a niños y adolescentes en riesgo mediante un procedimiento no invasivo;
- ayudaría a los profesionales a focalizar sus recursos;
- permitiría a las instituciones aprovechar datos que ya recolectan;
- daría a las familias señales de alerta tempranas;
- y la evaluación de su desempeño aportaría a la comunidad científica evidencia sobre el valor predictivo de estos indicadores.

> **DOS CONDICIONES PARA QUE SEA ÚTIL**
>
> 1. **Desempeño por nivel de severidad**, en particular su capacidad para no subestimar los casos severos, dado que en un tamizaje este error es más costoso que una remisión innecesaria.
> 2. **Interpretabilidad**, de modo que sus estimaciones puedan explicarse a los actores involucrados.
>
> **Alcance:** puesto que la evidencia sobre la capacidad predictiva de estos indicadores no es concluyente, el proyecto evalúa su capacidad para estimar el nivel de severidad registrado y, con ello, su potencial como insumo de un tamizaje, **sin implementarlo**.

1.4 Planteamiento del problema

> **EN POCAS PALABRAS**
>
> Los niños y adolescentes con PIU suelen ser identificados de forma tardía (Figura 1), y las mediciones físicas que podrían ayudar no se están usando.

- **Por qué ocurre.** La detección depende de una valoración profesional que no está al alcance de muchas familias [15], y los instrumentos de medición disponibles son heterogéneos y carecen de una referencia consolidada [2], [18].
- **Qué provoca.** El problema suele abordarse cuando el hábito ya se ha consolidado, y el PIU se asocia con depresión, ansiedad, agresividad y conducta suicida [1], así como con alteraciones del sueño [3], [4].
- **Qué se está dejando de aprovechar.** Las mediciones físicas que ya se recolectan de forma amplia no se emplean para identificar el riesgo de PIU, y la evidencia sobre su capacidad para hacerlo es contradictoria [16], [22], [23].

Sin una evaluación rigurosa del valor predictivo de estos indicadores, no es posible determinar si pueden servir como insumo para un tamizaje temprano y accesible.

PREGUNTA DE INVESTIGACIÓN

¿En qué medida los indicadores de actividad y aptitud física, junto con variables demográficas básicas, permiten estimar el nivel de severidad del PIU, medido mediante el SII, en niños y adolescentes del Healthy Brain Network, y cuál es el desempeño alcanzado en cada nivel de severidad en comparación con un modelo de referencia?

PREGUNTA COMPLEMENTARIA

¿Cuánto cambia ese desempeño al incorporar variables de sueño, funcionamiento global y uso de internet? Con ello se busca dimensionar la información que aportan los indicadores físicos frente a medidas de carácter psicológico, conductual o clínico.

1.5 Árbol de problemas

EN POCAS PALABRAS

De las tres causas de la detección tardía, el proyecto interviene sobre una: la desvinculación entre la identificación del riesgo y las mediciones que se recolectan de forma rutinaria.

Las otras dos causas, la dependencia de la valoración profesional y la heterogeneidad de los instrumentos de medición, se reconocen como parte del contexto del problema, pero quedan fuera del alcance de una solución basada en aprendizaje automático, ya que dependen de la disponibilidad de recursos clínicos y de la validación de los instrumentos.

La Figura 1 (página siguiente) organiza en un árbol de problemas las causas y los efectos de la detección tardía del PIU descritos en las secciones anteriores.

CÓMO LEER LA FIGURA 1

- **Abajo:** tres causas directas, cada una desagregada en dos subcausas.
- **Al centro:** el problema central, la detección tardía del PIU.
- **Arriba:** los efectos directos del problema y su consecuencia final sobre el bienestar y el desarrollo de niños y adolescentes.
- **Recuadro azul con borde discontinuo:** la causa sobre la que interviene el proyecto.
- **Flechas:** como la evidencia sobre el PIU y sus consecuencias proviene principalmente de estudios transversales, el árbol organiza asociaciones documentadas y no relaciones causales demostradas.

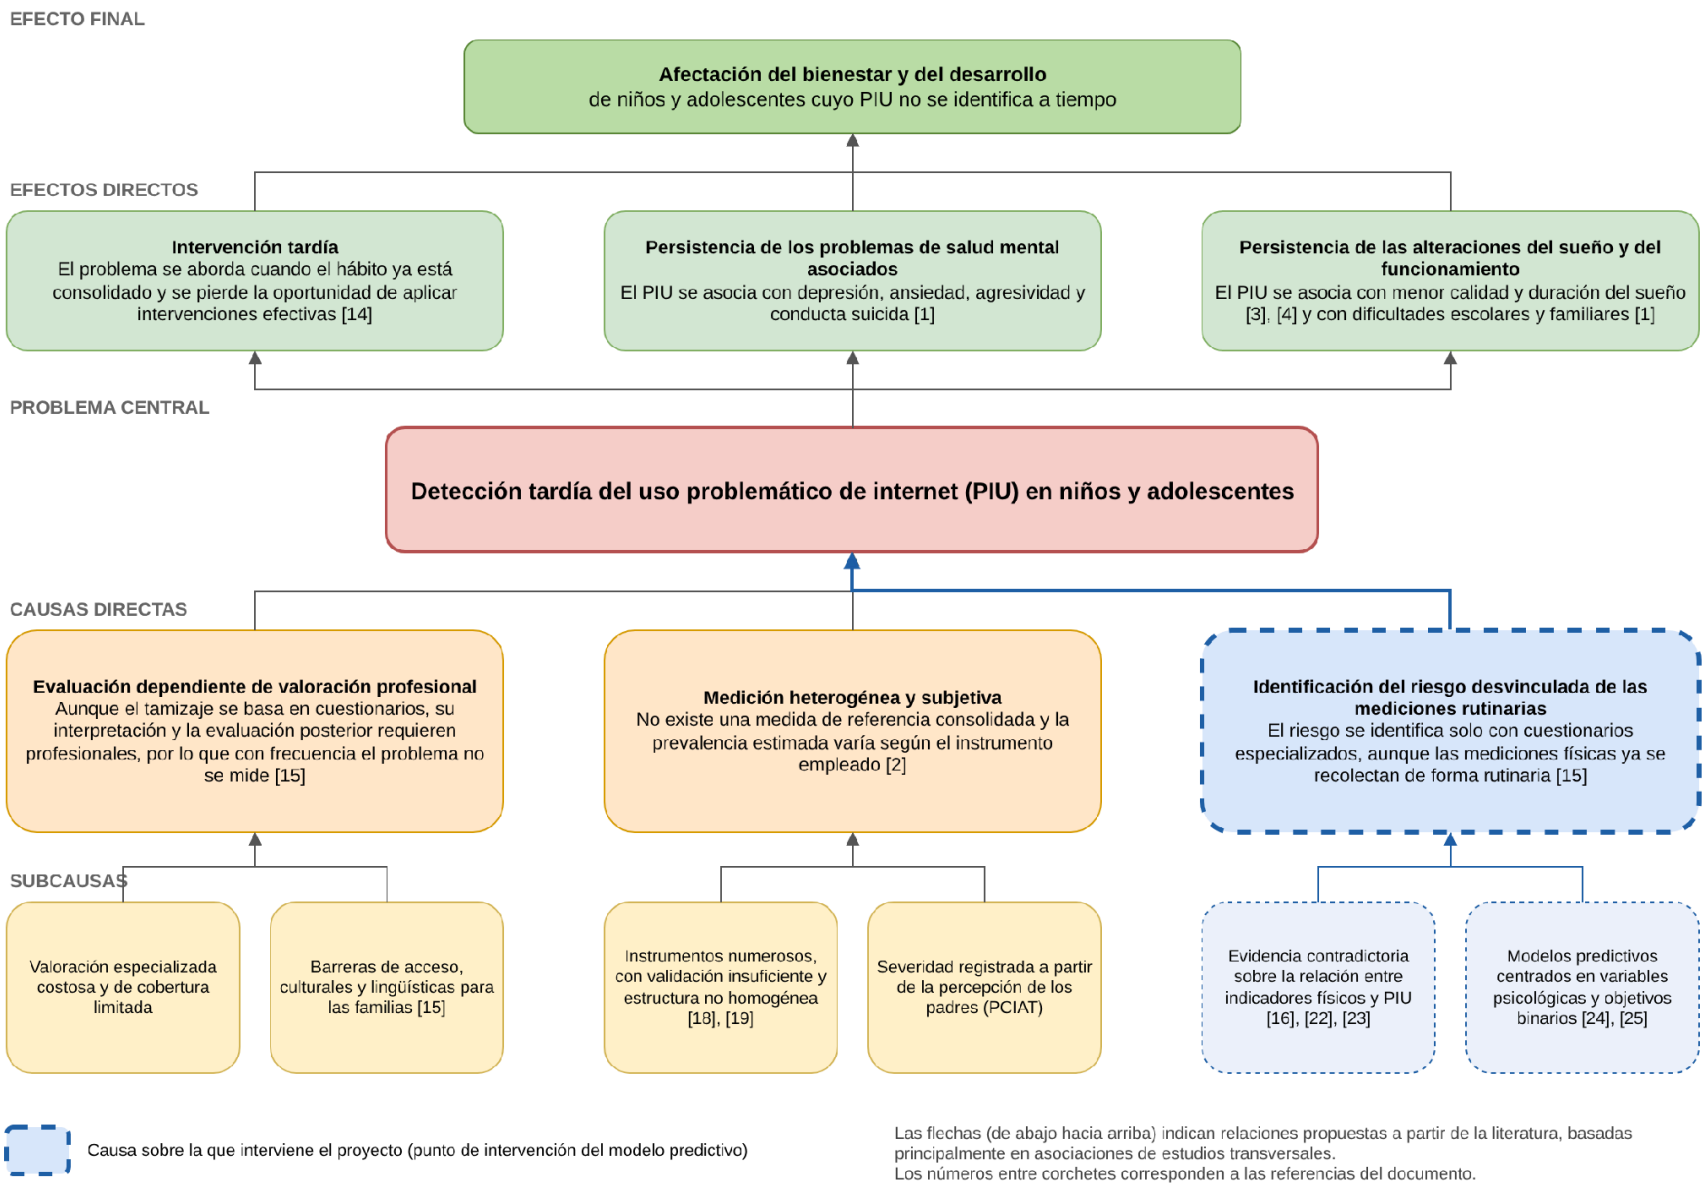


Figura 1. Árbol de problemas de la detección tardía del uso problemático de internet en niños y adolescentes. Los números entre corchetes corresponden a las referencias del documento. Elaboración propia.

1.6 Objetivos

EN POCAS PALABRAS

Un objetivo general y cinco específicos, cada uno con un criterio de verificación y una fecha límite.

OBJETIVO GENERAL · A MÁS TARDAR EL 1 DE DICIEMBRE DE 2026

Evaluar la capacidad de los indicadores de actividad y aptitud física, junto con variables demográficas básicas, para estimar el nivel de severidad del PIU, medido mediante el SII, en niños y adolescentes del Healthy Brain Network, a partir de modelos de aprendizaje automático supervisado, con el fin de determinar su potencial como insumo para un tamizaje temprano y accesible.

N.º	Objetivo específico	Fecha límite (2026)
1	Caracterizar la disponibilidad, la calidad y la distribución del SII, de los indicadores físicos y demográficos y de las variables complementarias en los datos del Healthy Brain Network, y definir el tratamiento de los datos faltantes y del desbalance entre niveles de severidad.	6 de noviembre
2	Desarrollar y comparar modelos de estimación ordinal del SII basados en indicadores físicos y demográficos, empleando modelos lineales regularizados, métodos de ensamble y máquinas de soporte vectorial, frente a un modelo de referencia, mediante validación cruzada estratificada y el QWK.	21 de noviembre
3	Analizar el desempeño del modelo seleccionado en cada nivel de severidad, con énfasis en su capacidad para no subestimar los casos severos, e identificar mediante técnicas de interpretabilidad los indicadores con mayor contribución a sus estimaciones.	25 de noviembre
4	Cuantificar el cambio en el desempeño al incorporar variables de sueño, funcionamiento global y uso de internet, comparando ambos conjuntos de variables bajo las mismas condiciones de evaluación.	22 de noviembre
5	Formular al menos tres recomendaciones exploratorias sobre el potencial de un tamizaje basado en indicadores físicos, como mínimo una por cada uno de los objetivos 2, 3 y 4, y al menos una acción de mejora, a partir de los resultados obtenidos y de sus limitaciones.	26 de noviembre

¿De dónde salen y por qué son SMART?

Los objetivos se derivan de la tercera causa del árbol de problemas y de sus subcausas, de las condiciones que debe cumplir un tamizaje según la sección 1.3 y de la pregunta formulada en la sección 1.4. Siguen el formato SMART:

Criterio	Cómo lo cumplen
Específicos	Cada uno se refiere a un análisis o producto concreto.
Medibles	Su cumplimiento se verifica con los criterios de la Tabla 2.
Alcanzables	Con los datos públicos disponibles y los recursos del equipo.
Relevantes	Responden a la causa y a las condiciones identificadas.
Acotados en el tiempo	Sus plazos coinciden con el cronograma de la sección 3.

El cumplimiento del objetivo general se verifica mediante los criterios de los objetivos específicos. La Tabla 2 relaciona cada objetivo específico con su origen y con el criterio que permite verificar su cumplimiento.

Tabla 2. Trazabilidad y criterios de cumplimiento de los objetivos específicos

Objetivo	Origen	Criterio de cumplimiento
1	Causa 3: desvinculación entre la identificación del riesgo y las mediciones rutinarias	Conjunto de datos analítico documentado, con la cobertura de cada grupo de variables, la distribución del SII, la comparación entre participantes con y sin SII y las decisiones de tratamiento justificadas
2	Subcausa: modelos predictivos centrados en variables psicológicas y objetivos binarios	Modelos con variables físicas y objetivo ordinal cuyo QWK en validación cruzada se compara con el de un modelo de referencia entrenado solo con variables demográficas
3	Condiciones del tamizaje (sección 1.3): desempeño por nivel e interpretabilidad	Matriz de confusión, recall por nivel de severidad, distribución de los casos severos entre los niveles asignados, comparación de los errores entre sexos y grupos de edad, y contribución de las variables del modelo seleccionado
4	Subcausa: evidencia contradictoria sobre la relación entre indicadores físicos y PIU; pregunta complementaria	Diferencia de desempeño entre ambos conjuntos de variables, evaluada sobre los mismos participantes y con el mismo procedimiento de validación
5	Alcance del proyecto: evaluar el potencial de los indicadores como insumo de un tamizaje	Al menos tres recomendaciones (mínimo una por objetivo 2, 3 y 4) y al menos una acción de mejora, registradas en una tabla que vincula cada una con su resultado (métrica, valor y variabilidad) y su limitación

1.7 Consideraciones éticas

EN POCAS PALABRAS

Datos sensibles, en su mayoría de menores de edad, una muestra que no representa a la población general y un modelo que no es una herramienta diagnóstica.

Protección de los datos

Los datos corresponden a participantes de 5 a 22 años, en su mayoría menores de edad, y contienen información sensible sobre su salud mental y física. Fueron publicados sin identificar a los participantes y su uso está sujeto a las reglas de la competencia que los puso a disposición [15]. Además, el equipo adoptó las siguientes medidas:

- los datos se emplean solo con fines académicos;
- se almacenan únicamente en los equipos de los integrantes;
- no se versionan en el repositorio público;
- no se realiza ningún intento de reidentificar a los participantes.

Límites para interpretar los resultados

Los resultados deben interpretarse considerando los sesgos propios de la muestra:

- **Muestra clínica, no representativa.** El Healthy Brain Network recluta a sus participantes en el área de Nueva York mediante referidos de la comunidad, por lo que se trata de una muestra clínica y no representativa de la población general [17]; las conclusiones no pueden extrapolarse directamente a otros contextos, como el colombiano.
- **Variable objetivo indirecta.** Proviene del reporte de los padres y no de una valoración clínica directa.
- **No es una herramienta diagnóstica.** Por estas razones, y en coherencia con el alcance definido en la sección 1.3, el modelo resultante no constituye una herramienta diagnóstica ni está destinado a su uso en la práctica: clasificar a un menor como «en riesgo» a partir de un modelo con capacidad predictiva limitada podría generar estigmatización, mientras que un falso negativo podría retrasar una atención necesaria. Cualquier aplicación futura requeriría validación clínica en la población de destino.
- **Equidad.** Como parte del análisis del desempeño, se examinará si los errores del modelo se distribuyen de manera desigual entre sexos y grupos de edad.

2 Cómo lo haremos

Metodología propuesta

El proyecto sigue la metodología **CRISP-DM** [29], que organiza un proyecto de minería de datos en seis fases iterativas. Así se distribuyen en el semestre:

1. Comprensión del negocio	2. Comprensión de los datos	3. Preparación de los datos	4. Modelado	5. Evaluación	6. Despliegue
Etapa 1 · Entrega 1 (sección 1)	Etapa 2	Etapa 2	Etapa 2: modelo de referencia y experimentos iniciales · Etapa 3: búsqueda completa y selección	Etapa 3	Fuera del alcance: se reemplaza por recomendaciones y acciones de mejora (objetivo 5)

El despliegue queda fuera del alcance porque el proyecto evalúa el potencial de los indicadores como insumo de un tamizaje y no lo implementa. En la etapa 2, el modelo de referencia y los experimentos iniciales ponen a prueba las hipótesis de la sección 2.5. Las subsecciones siguientes describen las decisiones metodológicas de las fases comprendidas en el alcance.

2.1 Recopilación de los datos

EN POCAS PALABRAS

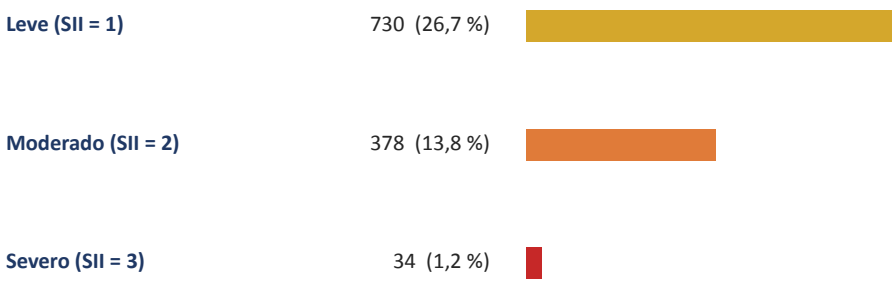
Se trabaja con 2.736 participantes etiquetados; los casos severos son muy pocos (34) y eso condiciona la validación y la evaluación.

3.960	1.224	2.736
participantes en el conjunto de entrenamiento, con 82 columnas	sin SII registrado (30,9 %)	participantes etiquetados: la base del análisis

- **Origen.** Los datos provienen de la competencia de Kaggle del Child Mind Institute [15], construida a partir de la muestra del Healthy Brain Network [17]. Las 82 columnas están organizadas por instrumento de medición y documentadas en un diccionario de datos.
- **Actigrafía.** La competencia incluye además series de actigrafía, registradas con un acelerómetro de pulsera, para un subconjunto de los participantes. Su incorporación, mediante variables resumen por participante, se decide durante la caracterización de los datos según su cobertura.
- **Por qué solo el conjunto de entrenamiento.** El conjunto de prueba de la competencia está oculto, y el archivo público contiene 20 registros de ejemplo que corresponden a participantes del conjunto de entrenamiento. Por ello, el entrenamiento y la evaluación se realizan sobre los participantes etiquetados del conjunto de entrenamiento.
- **Trazabilidad de las cifras.** Las cifras descriptivas de esta sección y de la Tabla 3 se calculan con el código del repositorio descrito en la sección 2.7.

Distribución del SII en los 2.736 participantes etiquetados

Ninguno (SII = 0)	1.594 (58,3 %)	



Los participantes sin SII se comparan con los etiquetados en las variables disponibles para ambos grupos, como la edad, el sexo y la cobertura de los instrumentos, para identificar si su exclusión limita la generalización de los resultados. Si se observan diferencias, las conclusiones se restringen a la población etiquetada.

La escasez de casos severos condiciona las decisiones de validación y evaluación descritas en la sección 2.5.

2.2 Grupos de variables y modelos comparados

EN POCAS PALABRAS

Tres grupos de variables, combinados en cuatro conjuntos, se comparan sobre los mismos participantes y con el mismo protocolo.

Las variables predictoras se agrupan según la pregunta de investigación a la que responden (Tabla 3).

Tabla 3. Grupos de variables predictoras y su cobertura en los participantes etiquetados

Grupo	Instrumento o medida	Cobertura
Demográfico	Edad, sexo y temporada de inscripción	100 %
Físico	Medidas antropométricas y signos vitales	94,2 %
Físico	Aptitud física (FitnessGram)	70,2 %
Físico	Resistencia cardiorrespiratoria	26,7 %
Físico	Composición corporal por bioimpedancia	66,3 %
Físico	Actividad física autorreportada (PAQ)	65,9 %
Complementario	Alteraciones del sueño (SDS)	92,4 %
Complementario	Funcionamiento global (CGAS)	85,6 %
Complementario	Horas diarias de uso de computador e internet	97,0 %

La cobertura de un instrumento es la proporción de participantes etiquetados con al menos una de sus variables registrada, sin contar las columnas de temporada y antes del tratamiento de valores inválidos.

A partir de estos grupos se definen cuatro conjuntos de variables:

Referencia
Solo el grupo demográfico.

Principal
Los grupos demográfico y físico.

Complementario
Los tres grupos.

Principal sin actigrafía
El conjunto principal sin las variables de actigrafía, para aislar su aporte. Se evalúa si la caracterización de los datos lleva a incorporarlas.

Cómo se comparan

- Los experimentos iniciales evalúan todos los conjuntos con las mismas configuraciones (sección 2.4).
- En la búsqueda completa, los modelos se comparan con el conjunto principal, y la configuración seleccionada —es decir, el algoritmo, la formulación del SII y el tratamiento de los datos— se entrena después con los demás conjuntos.
- Los hiperparámetros se reajustan para cada conjunto en la validación interna, de modo que las diferencias de desempeño reflejan la información que aportan las variables bajo un mismo protocolo de modelado. Como la configuración se elige con el conjunto principal, la comparación queda condicionada a ese protocolo.
- Todos los conjuntos se entrenan y evalúan sobre los mismos 2.736 participantes y con las mismas particiones. Un participante sin registro en un instrumento permanece en el análisis, y su ausencia se gestiona como se describe en la sección 2.3.

2.3 Preparación de los datos

EN POCAS PALABRAS

Seis decisiones de preparación; todas las que se ajustan con datos (imputación, escalado, pesos) usan solo la partición de entrenamiento.

Decisión	Qué se hace y por qué
Prevención de fuga de información	Se excluyen los ítems, el puntaje total y la temporada del PCIAT: estas columnas existen solo en el conjunto de entrenamiento y determinan directamente el SII, por lo que su uso produciría estimaciones de desempeño irreales. También se excluye el identificador del participante.
Valores inválidos	Los valores fisiológicamente imposibles, como medidas antropométricas o de bioimpedancia nulas o negativas, se identifican durante la caracterización de los datos y se tratan como faltantes.
Selección de variables	Se basa únicamente en la cobertura, la plausibilidad y la redundancia con otros predictores, nunca en la relación con el SII, de modo que no depende de las etiquetas usadas en la evaluación. Con este criterio se deciden también la incorporación de la actigrafía y el tratamiento de las variables de muy baja cobertura, como la resistencia cardiorrespiratoria.
Valores faltantes	Aparecen por bloques, porque corresponden a instrumentos que un participante no completó. Se consideran tres estrategias: (1) el manejo nativo de faltantes de los algoritmos de gradient boosting; (2) la imputación simple (mediana o moda) acompañada de variables indicadoras de ausencia; (3) la imputación multivariada. En la búsqueda completa, la estrategia se trata como un hiperparámetro y se selecciona en la validación interna de cada partición. En los experimentos iniciales, cada familia usa una estrategia fija: manejo nativo en gradient boosting e imputación simple con variables indicadoras de ausencia en los modelos lineales. Toda imputación se ajusta únicamente con los datos de entrenamiento de cada partición, dentro de un flujo de procesamiento encadenado, para que la partición de evaluación no influya en el ajuste.
Codificación y escalado	Las variables binarias se conservan como 0 y 1, las ordinales como códigos enteros y la temporada de inscripción mediante codificación one-hot. Para los modelos sensibles a la escala (lineales y máquinas de soporte vectorial), las variables numéricas se transforman con Yeo-Johnson [30], que reduce su asimetría, y se estandarizan; las ordinales solo se estandarizan. Todos los parámetros se calculan en la partición de entrenamiento.
Desbalance entre niveles	Se asignan pesos inversamente proporcionales a la frecuencia de cada nivel, calculada en la partición de entrenamiento de cada ajuste, de modo que los errores en los niveles minoritarios tengan mayor peso. En la clasificación multiclase los pesos se asignan por nivel; en la descomposición ordinal, cada clasificador binario pondera sus dos clases; y en la regresión, cada observación recibe el peso de su nivel.

2.4 Técnicas de modelado

EN POCAS PALABRAS

Tres familias de algoritmos, cada una evaluada con tres formas de modelar el SII, que es ordinal: sus niveles tienen un orden natural, de ninguno a severo.

Tres familias de algoritmos

Modelos lineales regularizados

Regresión logística para las formulaciones de clasificación y regresión lineal para la de regresión.

Baja varianza y coeficientes directamente interpretables. En un estudio previo sobre el PIU, la regresión logística alcanzó un desempeño comparable al de los bosques aleatorios [24]. Permiten determinar si los modelos más complejos aportan información adicional.

Ensambles de árboles

Bosques aleatorios y gradient boosting.

Han mostrado un desempeño superior al de las redes neuronales profundas en conjuntos tabulares de tamaño medio [27] y no requieren escalado; algunas de sus implementaciones manejan además los valores faltantes de forma nativa.

Máquinas de soporte vectorial

Con kernel radial.

Alternativa basada en un principio distinto.

Tres formulaciones de la variable objetivo

Formulación	Cómo funciona
Clasificación multiclase nominal	Ignora el orden entre niveles y sirve como formulación base; en el caso de la regresión logística corresponde a su versión multinomial.
Descomposición ordinal de Frank y Hall [28]	Se entrenan tres clasificadores binarios que estiman $P(SII > k)$ para $k = 0, 1, 2$. Las probabilidades de cada nivel se obtienen por diferencia entre estimaciones consecutivas: $P(SII = 0) = 1 - P(SII > 0)$; $P(SII = k) = P(SII > k - 1) - P(SII > k)$ para $k = 1, 2$; y $P(SII = 3) = P(SII > 2)$. Como los clasificadores se entrenan por separado, sus probabilidades acumuladas pueden no ser decrecientes en k; para garantizar probabilidades válidas, se aplica a $P(SII > k)$ el mínimo acumulado sobre k antes de calcular las diferencias, y se asigna el nivel de mayor probabilidad.
Regresión con umbrales	El SII se estima como una variable continua y luego se discretiza con tres umbrales, optimizados para maximizar la métrica de evaluación sobre las predicciones de validación interna de cada partición de entrenamiento.

Validación cruzada anidada. Los hiperparámetros —incluidos el tipo y la intensidad de la regularización y la estrategia de tratamiento de los faltantes— y los umbrales se seleccionan mediante validación interna dentro de cada partición de entrenamiento. De esta forma, las particiones de evaluación no intervienen en ninguna decisión de ajuste.

Experimentos iniciales. Antes de la búsqueda completa, dos configuraciones se evalúan con todos los conjuntos de variables para verificar el flujo de validación y poner a prueba las hipótesis de la sección 2.5: una regresión logística multinomial y un gradient boosting, ambos en la formulación multiclase, con pesos por nivel y una búsqueda reducida de hiperparámetros en la validación interna.

2.5 Validación y métricas de evaluación

EN POCAS PALABRAS

El QWK es la métrica principal, pero no basta: en un tamizaje, subestimar un caso moderado o severo es más grave que sobrestimar uno leve, así que se complementa con medidas por nivel.

Esquema de validación

5 × 5	3	≈ 7
Validación externa: validación cruzada estratificada por SII con cinco particiones, repetida cinco veces con semillas fijas y distintas.	**Validación interna:** tres particiones estratificadas dentro de cada partición de entrenamiento, para seleccionar hiperparámetros, estrategia de faltantes y umbrales.	**Casos severos por partición de evaluación**, de los 34 disponibles.

Métrica principal: QWK

La métrica principal es el coeficiente kappa ponderado cuadrático (QWK) [31], la misma métrica oficial de la competencia [15]:

$$\kappa = 1 - \frac{\sum_{i,j} w_{ij} O_{ij}}{\sum_{i,j} w_{ij} E_{ij}}, \quad w_{ij} = \frac{(i-j)^2}{(K-1)^2} \qquad (1)$$

- **O** es la matriz de confusión observada.
- **E** es la matriz esperada por azar, calculada a partir de las distribuciones marginales.
- **K** = 4 es el número de niveles.
- $\boldsymbol{w}_{ij}$ es el peso del error entre el nivel real *i* y el estimado *j*: crece con el cuadrado de la distancia entre ambos.

El coeficiente penaliza los errores en proporción al cuadrado de la distancia entre el nivel real y el estimado. Vale **1** cuando la concordancia es perfecta y **0** cuando equivale al azar.

POR QUÉ EL QWK NO BASTA

El QWK es simétrico: sobrestimar o subestimar un nivel en la misma magnitud tiene el mismo costo. En un tamizaje, en cambio, subestimar un caso moderado o severo es más grave que sobrestimar uno leve. Por esta razón, el QWK se complementa con tres medidas:

1. la **matriz de confusión**;
2. el **recall por nivel**, es decir, la proporción de participantes de cada nivel a los que se asigna ese nivel;
3. la **tasa de subestimación**, definida como la proporción de participantes con SII moderado o severo a los que se asigna un nivel inferior al real.

En el nivel severo, toda asignación incorrecta es una subestimación, por lo que su tasa equivale a uno menos su recall. En su lugar, para ese nivel se reporta la distribución de los casos severos entre los niveles asignados.

Cómo se reportan los resultados

- **Agregación.** El QWK se calcula en cada partición de evaluación y se promedia por repetición. La matriz de confusión, el recall y la tasa de subestimación se calculan sobre las predicciones de las cinco particiones de cada repetición, en las que cada participante tiene exactamente una predicción. Los resultados se reportan como media y desviación estándar entre repeticiones; esta desviación describe la estabilidad del resultado frente a la partición de los datos y no la incertidumbre de generalización.
- **Controles.** Como límite inferior se usan dos clasificadores sin información: uno que asigna siempre el nivel más frecuente y uno que asigna niveles al azar según la distribución de entrenamiento.
- **Inestabilidad en el nivel severo.** Con 34 casos severos, cada partición de evaluación tiene unos 7, así que un solo caso cambia el recall de esa partición en unos 14 puntos porcentuales. Por eso el recall severo no se interpreta por partición: se calcula sobre los 34 casos de cada repetición y se reporta con su intervalo de confianza del 95 % (método de Wilson [32]). Se considera inestable si su desviación estándar entre las cinco repeticiones supera 0,10, es decir, unos tres casos severos.
- **Plan si resulta inestable.** (1) La evaluación del modelo seleccionado se amplía a diez repeticiones, lo que estabiliza la estimación frente a la partición de los datos, aunque no reduce la incertidumbre propia de contar con solo 34 casos. (2)

La conclusión sobre la capacidad de no subestimar se apoya en la tasa de subestimación del grupo moderado o severo (412 casos), y el resultado del nivel severo se reporta como descriptivo: la distribución de los 34 casos entre los niveles asignados y cuántos se clasifican igual en todas las repeticiones. (3) Ninguna decisión de selección de modelos depende solo del recall severo, y la limitación se traslada a las recomendaciones del objetivo 5.

Hipótesis de los experimentos iniciales

Los experimentos iniciales ponen a prueba las hipótesis de la Tabla 4. La prueba de H3 se realiza solo si la caracterización de los datos lleva a incorporar la actigrafía.

Tabla 4. Hipótesis de los experimentos iniciales

Hipótesis	Enunciado	Prueba	Objetivo
H1	El QWK del modelo entrenado con el conjunto de referencia supera el esperado por azar	Prueba de permutación	2
H2	El conjunto principal alcanza un QWK mayor que el de referencia, con una ganancia que se espera pequeña [23]	t corregida pareada	2
H3	El conjunto principal alcanza un QWK mayor que el principal sin actigrafía	t corregida pareada	2
H4	El conjunto complementario alcanza un QWK mayor que el principal	t corregida pareada	4

- **Inferencia para H1.** El SII se permuta 200 veces y, con cada permutación, se repite el procedimiento de validación con la regresión logística en una repetición del esquema externo. El valor p es (1 + B) / (1 + 200), donde B es el número de permutaciones con un QWK igual o mayor que el observado [33].
- **Inferencia para H2 a H4.** La diferencia de QWK se calcula en cada partición sobre los mismos participantes. Como las particiones comparten participantes y datos de entrenamiento, esas diferencias no son independientes; por ello se usa la prueba t corregida de Nadeau y Bengio [34], unilateral, y los valores p se ajustan con el método de Holm [35] sobre el conjunto de pruebas pareadas.

Regla para elegir el modelo final

1. Se identifica la configuración con mayor QWK medio en la búsqueda completa.
2. Entre las configuraciones cuya diferencia frente a ella no es significativa según la prueba t corregida ($\alpha = 0{,}05$), se selecciona la de menor tasa de subestimación.
3. Si persiste el empate, se elige la de menor complejidad.

Como la selección se hace con las mismas particiones con las que se reporta el desempeño, el QWK de la configuración seleccionada tiene un sesgo optimista, que se declara al reportarlo.

ESCENARIO DE TAMIZAJE

Para valorar el potencial de los indicadores como insumo de un tamizaje, las predicciones se traducen a un escenario de remisión en el que **se remite a todo participante con nivel estimado moderado o severo**. En ese escenario se reportan el recall, la especificidad, el valor predictivo positivo y la proporción de participantes remitidos. Como no existe un umbral clínico de desempeño aceptable, las recomendaciones del objetivo específico 5 son exploratorias y no clínicas.

2.6 Interpretabilidad y análisis de errores

EN POCAS PALABRAS

Entender qué variables pesan en las estimaciones del modelo y si se equivoca más con algunos grupos de participantes.

Contribución de las variables (SHAP)

La contribución de cada variable al modelo seleccionado se analiza con valores SHAP [36], que descomponen cada estimación en aportes aditivos por variable y permiten identificar tanto las variables más influyentes como la dirección de su contribución. La salida explicada depende de la formulación:

- **clasificación multiclase:** la probabilidad de cada nivel;
- **descomposición ordinal:** la probabilidad acumulada P(SII > 1), es decir, de un nivel moderado o severo;
- **regresión:** la estimación continua.

Los valores SHAP describen contribuciones a la predicción del modelo y **no efectos causales**, y se informa si el orden de importancia de las variables se mantiene entre repeticiones.

Errores por sexo y grupo de edad

El análisis de errores compara el QWK, el recall por nivel y la tasa de subestimación entre sexos y entre tres grupos de edad: **5 a 12 años, 13 a 17 años y 18 a 22 años**. El tamaño de cada subgrupo se reporta junto con sus resultados, para no sobreinterpretar diferencias calculadas con pocos casos.

La comparación entre grupos de edad se apoya además en la evidencia sobre la mayor sensibilidad a las recompensas durante la adolescencia [6], [7] y en que la literatura no establece en qué etapa, entre la infancia, la adolescencia y la adultez temprana, es mayor la vulnerabilidad al PIU [10], [11], [12] (sección 1.1). Como el proyecto no dispone de medidas cerebrales, este análisis es descriptivo y no pone a prueba esa explicación. Además, como el SII proviene del reporte de los padres, las diferencias entre grupos de edad pueden reflejar también diferencias en lo que los padres observan del uso de internet de sus hijos.

Los hallazgos de esta fase y de la anterior sustentan las recomendaciones exploratorias del objetivo específico 5.

2.7 Herramientas y reproducibilidad

Aspecto	Detalle
Lenguaje y bibliotecas	Python con pandas, scikit-learn [37] y SHAP; el gradient boosting se implementa con HistGradientBoostingClassifier de scikit-learn.
Dependencias	Se gestionan con uv para fijar versiones exactas.
Código	Organizado en un paquete reutilizable y en cuadernos de análisis, versionados en un repositorio público de GitHub (github.com/juanestebancg2806/piu-severity-prediction).
Reproducibilidad	Todas las particiones y modelos usan semillas fijas, y la exclusión de las variables del PCIAT se implementa en el código y no de forma manual, para que los resultados puedan reproducirse.

3 Plan de trabajo

Planeación: actividades y cronograma

El proyecto se organiza en **tres fases** que coinciden con las entregas del curso y con las fases de CRISP-DM descritas en la sección 2. Las actividades se derivan de los objetivos específicos. Cada bloque del cronograma tiene un responsable de su ejecución y un revisor distinto, que revisa el código y los resultados del bloque antes de integrarlos; además, el equipo revisa en conjunto los avances antes de cada entrega. Los dos bloques de Juan Esteban Cardona concentran la mayor carga entre el 27 de octubre y el 21 de noviembre; por eso sus revisores siguen el código desde el inicio y pueden asumir parte de la ejecución si un bloque se retrasa.

3.1 Actividades por objetivo

Objetivo	Actividades
1	Documentar la estructura de los datos y caracterizarlos mediante un análisis exploratorio: cobertura de cada grupo de variables, patrón de los valores faltantes, distribución del SII y de los predictores, comparación entre participantes con y sin SII, correlación entre predictores y relación descriptiva de cada grupo de variables con el SII, que no interviene en la selección de variables. Con base en este análisis, identificar los valores inválidos, decidir la incorporación de las series de actigrafía y definir las estrategias candidatas de tratamiento de los faltantes y la ponderación de las clases.
2	Implementar el flujo de preparación de los datos y de validación cruzada anidada y repetida; entrenar el modelo de referencia y realizar los experimentos iniciales con todos los conjuntos de variables; entrenar con el conjunto principal los modelos lineales regularizados, los ensambles y las máquinas de soporte vectorial en sus tres formulaciones; seleccionar la configuración final según la regla de selección y entrenarla con el conjunto de referencia.
3	Calcular la matriz de confusión, el recall por nivel, la tasa de subestimación y la distribución de los casos severos entre los niveles asignados del modelo seleccionado; calcular las métricas del escenario de tamizaje; analizar la contribución de las variables mediante valores SHAP y comparar los errores entre sexos y grupos de edad.
4	Entrenar la configuración seleccionada con el conjunto complementario sobre las mismas particiones y cuantificar la diferencia pareada de desempeño frente al conjunto principal.
5	Sintetizar los resultados y las limitaciones de los objetivos 2 a 4; formular al menos tres recomendaciones exploratorias y al menos una acción de mejora, y construir la tabla que vincula cada una con su resultado y su limitación.

3.2 Cronograma

El modelo de referencia y los experimentos iniciales de la fase 2 verifican el flujo de validación y ponen a prueba las hipótesis de la Tabla 4. La Entrega 2 aporta resultados y no repite la metodología de este documento: (1) el análisis exploratorio del objetivo 1, con la cobertura de cada grupo de variables, el patrón de los valores faltantes, la comparación entre participantes con y sin SII y las decisiones de tratamiento; (2) el desempeño del modelo de referencia frente a los dos clasificadores sin información; y (3) las primeras pruebas de las hipótesis H1 a H4 con las configuraciones de los experimentos iniciales (H3, solo si se incorpora la actigrafía). De la metodología, solo documenta los cambios que surjan del análisis exploratorio. La búsqueda completa de modelos se realiza en la fase 3. En esa fase, el objetivo 4 se ejecuta al final del bloque de modelado, una vez seleccionada la configuración, y el análisis del objetivo 3 parte de esa misma configuración.

Tabla 5. Cronograma del proyecto

Fase	Actividades principales	Duración estimada	Responsable y revisor	Recursos necesarios
1. Formulación	Análisis del problema, estado del arte, árbol de problemas, objetivos, metodología y planeación; configuración del repositorio. Entrega 1.	Hasta el 19 de octubre	Katherin Camargo	Artículos científicos, datos de Kaggle, Google Docs, draw.io, GitHub

Fase	Actividades principales	Duración estimada	Responsable y revisor	Recursos necesarios
2. Comprensión y preparación de los datos	Análisis exploratorio y tratamiento de los datos (objetivo 1)	20 de octubre – 6 de noviembre	Juan David Martínez Revisa: Daniel Velasco	Python, pandas, scikit-learn
	Flujo de validación, modelo de referencia y experimentos iniciales (objetivo 2)	27 de octubre – 9 de noviembre	Juan Esteban Cardona Revisa: Katherin Camargo	Python, scikit-learn, uv, GitHub
	Redacción de la Entrega 2: resultados del análisis exploratorio, del modelo de referencia y de las primeras pruebas de hipótesis	10 – 13 de noviembre	Equipo	Google Docs
	Revisión final y Entrega 2	14 de noviembre	Equipo	—
3. Modelado y evaluación	Búsqueda, comparación y selección de modelos (objetivo 2)	15 – 21 de noviembre	Juan Esteban Cardona Revisa: Daniel Velasco	Python, scikit-learn
	Comparación con el conjunto complementario (objetivo 4)	21 – 22 de noviembre	Daniel Velasco Revisa: Juan Esteban Cardona	Python, scikit-learn
	Análisis por nivel, interpretabilidad y errores por subgrupo (objetivo 3)	22 – 25 de noviembre	Daniel Velasco Revisa: Juan David Martínez	Python, SHAP
	Recomendaciones y acciones de mejora (objetivo 5)	25 – 26 de noviembre	Equipo	Resultados de las fases anteriores
	Informe final	24 – 29 de noviembre	Katherin Camargo Revisa: Juan Esteban Cardona	Google Docs
	Video y presentación oral	26 – 29 de noviembre	Juan David Martínez Revisa: Katherin Camargo	Software de grabación y edición, diapositivas
	Revisión final y margen ante imprevistos	30 de noviembre	Equipo	—
	Entrega final	1 de diciembre	Equipo	—

Referencias

[1] E. Soriano-Molina, R. M. Limiñana-Gras, R. M. Patró-Hernández y M. Rubio-Aparicio, "The association between internet addiction and adolescents' mental health: A meta-analytic review," *Behavioral Sciences*, vol. 15, no. 2, p. 116, 2025, doi: 10.3390/bs15020116.

[2] Y.-C. Pan, Y.-C. Chiu y Y.-H. Lin, "Systematic review and meta-analysis of epidemiology of internet addiction," *Neuroscience & Biobehavioral Reviews*, vol. 118, pp. 612–622, 2020, doi: 10.1016/j.neubiorev.2020.08.013.

[3] I. Kokka *et al.*, "Exploring the effects of problematic internet use on adolescent sleep: A systematic review," *International Journal of Environmental Research and Public Health*, vol. 18, no. 2, p. 760, 2021, doi: 10.3390/ijerph18020760.

[4] X. Mei *et al.*, "Sleep problems in excessive technology use among adolescent: a systemic review and meta-analysis," *Sleep Science and Practice*, vol. 2, art. 9, 2018, doi: 10.1186/s41606-018-0028-9.

[5] B. J. Casey, R. M. Jones y T. A. Hare, "The adolescent brain," *Annals of the New York Academy of Sciences*, vol. 1124, no. 1, pp. 111–126, 2008, doi: 10.1196/annals.1440.010.

[6] E. P. Shulman *et al.*, "The dual systems model: Review, reappraisal, and reaffirmation," *Developmental Cognitive Neuroscience*, vol. 17, pp. 103–117, 2016, doi: 10.1016/j.dcn.2015.12.010.

[7] A. Galván *et al.*, "Earlier development of the accumbens relative to orbitofrontal cortex might underlie risk-taking behavior in adolescents," *Journal of Neuroscience*, vol. 26, no. 25, pp. 6885–6892, 2006, doi: 10.1523/JNEUROSCI.1062-06.2006.

[8] L. E. Sherman, A. A. Payton, L. M. Hernandez, P. M. Greenfield y M. Dapretto, "The power of the like in adolescence: Effects of peer influence on neural and behavioral responses to social media," *Psychological Science*, vol. 27, no. 7, pp. 1027–1035, 2016, doi: 10.1177/0956797616645673.

[9] M. T. Maza *et al.*, "Association of habitual checking behaviors on social media with longitudinal functional brain development," *JAMA Pediatrics*, vol. 177, no. 2, pp. 160–167, 2023, doi: 10.1001/jamapediatrics.2022.4924.

[10] R. Lozano-Blasco, M. P. Latorre-Martínez y A. Cortés-Pascual, "Screen addicts: A meta-analysis of internet addiction in adolescence," *Children and Youth Services Review*, vol. 135, art. 106373, 2022, doi: 10.1016/j.childyouth.2022.106373.

[11] L. E. Sherman, P. M. Greenfield, L. M. Hernandez y M. Dapretto, "Peer influence via Instagram: Effects on brain and behavior in adolescence and young adulthood," *Child Development*, vol. 89, no. 1, pp. 37–47, 2018, doi: 10.1111/cdev.12838.

[12] R. Lozano-Blasco, A. Quilez Robres y A. Soto Sánchez, "Internet addiction in young adults: A meta-analysis and systematic review," *Computers in Human Behavior*, vol. 130, art. 107201, 2022, doi: 10.1016/j.chb.2022.107201.

[13] E. A. Crone y E. A. Konijn, "Media use and brain development during adolescence," *Nature Communications*, vol. 9, art. 588, 2018, doi: 10.1038/s41467-018-03126-x.

[14] L. Wang, Y. Chen, J. H. Cho, H. Yang y J. C. Seo, "Effectiveness of exercise as an intervention for internet addiction in adolescents: a meta-analysis," *PeerJ*, vol. 13, e19999, 2025, doi: 10.7717/peerj.19999.

[15] Child Mind Institute y Kaggle, "Child Mind Institute — Problematic Internet Use," Kaggle, 2024. [En línea]. Disponible: https://www.kaggle.com/competitions/child-mind-institute-problematic-internet-use

[16] G. Han *et al.*, "Prevalence of internet addiction and its relationship with combinations of physical activity and screen-based sedentary behavior among adolescents in China," *Journal of Physical Activity and Health*, vol. 18, no. 10, pp. 1245–1252, 2021, doi: 10.1123/jpah.2020-0512.

[17] L. M. Alexander *et al.*, "An open resource for transdiagnostic research in pediatric mental health and learning disorders," *Scientific Data*, vol. 4, art. 170181, 2017, doi: 10.1038/sdata.2017.181.

[18] S. Laconi, R. F. Rodgers y H. Chabrol, "The measurement of Internet addiction: A critical review of existing scales and their psychometric properties," *Computers in Human Behavior*, vol. 41, pp. 190–202, 2014, doi: 10.1016/j.chb.2014.09.026.

[19] M. K. Chang y S. P. M. Law, "Factor structure for Young's Internet Addiction Test: A confirmatory study," *Computers in Human Behavior*, vol. 24, no. 6, pp. 2597–2619, 2008, doi: 10.1016/j.chb.2008.03.001.

[20] Child Mind Institute, "Screen time struggles: What a data science competition taught us about problematic internet use in teens," 2025. [En línea]. Disponible: https://childmind.org/blog/screen-time-struggles/

[21] C. Ma, J. Yan, H. Hu, C. Shi, F. Li y X. Zeng, "Associations between 24-h movement behavior and internet addiction in adolescents: A cross-sectional study," *International Journal of Environmental Research and Public Health*, vol. 19, no. 24, p. 16873, 2022, doi: 10.3390/ijerph192416873.

[22] W. Xiao *et al.*, "The relationship between physical activity and mobile phone addiction among adolescents and young adults: Systematic review and meta-analysis of observational studies," *JMIR Public Health and Surveillance*, vol. 8, no. 12, e41606, 2022, doi: 10.2196/41606.

[23] A. Restrepo *et al.*, "Problematic internet use in children and adolescents: associations with psychiatric disorders and impairment," *BMC Psychiatry*, vol. 20, art. 252, 2020, doi: 10.1186/s12888-020-02640-x.

[24] K. Ioannidis *et al.*, "Problematic internet use (PIU): Associations with the impulsive-compulsive spectrum. An application of machine learning in psychiatry," *Journal of Psychiatric Research*, vol. 83, pp. 94–102, 2016, doi: 10.1016/j.jpsychires.2016.08.010.

[25] J. Liu *et al.*, "Explainable machine learning prediction of internet addiction among Chinese primary and middle school children and adolescents: a longitudinal study based on positive youth development data (2019–2022)," *Frontiers in Public Health*, vol. 13, art. 1590689, 2025, doi: 10.3389/fpubh.2025.1590689.

[26] K. R. Niteesh y T. S. Pooja, "Predicting problematic internet use in children using feature-rich structured data with ensemble machine learning and Bayesian optimisation," en *Proc. Asia-Pacific Signal and Information Processing Association Annual Summit and Conference (APSIPA ASC)*, 2025, pp. 1627–1632, doi: 10.1109/APSIPAASC65261.2025.11249107.

[27] L. Grinsztajn, E. Oyallon y G. Varoquaux, "Why do tree-based models still outperform deep learning on typical tabular data?," en *Advances in Neural Information Processing Systems*, vol. 35 (Datasets and Benchmarks Track), 2022, pp. 507–520.

[28] E. Frank y M. Hall, "A simple approach to ordinal classification," en *Machine Learning: ECML 2001*, Lecture Notes in Computer Science, vol. 2167. Berlín: Springer, 2001, pp. 145–156, doi: 10.1007/3-540-44795-4_13.

[29] R. Wirth y J. Hipp, "CRISP-DM: Towards a standard process model for data mining," en *Proc. 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining*, Mánchester, Reino Unido, 2000, pp. 29–39. [En línea]. Disponible: https://www.cs.unibo.it/~danilo.montesi/CBD/Beatriz/10.1.1.198.5133.pdf

[30] I.-K. Yeo y R. A. Johnson, "A new family of power transformations to improve normality or symmetry," *Biometrika*, vol. 87, no. 4, pp. 954–959, 2000, doi: 10.1093/biomet/87.4.954.

[31] J. Cohen, "Weighted kappa: Nominal scale agreement provision for scaled disagreement or partial credit," *Psychological Bulletin*, vol. 70, no. 4, pp. 213–220, 1968, doi: 10.1037/h0026256.

[32] E. B. Wilson, "Probable inference, the law of succession, and statistical inference," *Journal of the American Statistical Association*, vol. 22, no. 158, pp. 209–212, 1927, doi: 10.1080/01621459.1927.10502953.

[33] M. Ojala y G. C. Garriga, "Permutation tests for studying classifier performance," *Journal of Machine Learning Research*, vol. 11, pp. 1833–1863, 2010.

[34] C. Nadeau y Y. Bengio, "Inference for the generalization error," *Machine Learning*, vol. 52, no. 3, pp. 239–281, 2003, doi: 10.1023/A:1024068626366.

[35] S. Holm, "A simple sequentially rejective multiple test procedure," *Scandinavian Journal of Statistics*, vol. 6, no. 2, pp. 65–70, 1979.

[36] S. M. Lundberg y S.-I. Lee, "A unified approach to interpreting model predictions," en *Advances in Neural Information Processing Systems*, vol. 30, 2017, pp. 4765–4774.

[37] F. Pedregosa *et al.*, "Scikit-learn: Machine learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.