SEGUNDA ENTREGA · REPORTE DE LA SEGUNDA ETAPA

Evaluación de indicadores de actividad y aptitud física para estimar la severidad del uso problemático de internet en niños y adolescentes mediante aprendizaje automático

> *Lo que mostraron los datos, el modelo de referencia y las primeras pruebas de hipótesis*

Autores:
Katherin A. Camargo Cetina, Juan E. Cardona García, Juan D. Martínez Legarda y Daniel Velasco López
Profesor: Milton Orlando Sarria

Proyecto I de Innovación Tecnológica en Inteligencia Artificial · Maestría en Inteligencia Artificial Aplicada · Universidad Icesi, Cali, Colombia · Noviembre de 2026

Repositorio: https://github.com/juanestebancg2806/piu-severity-prediction

LA ETAPA EN CUATRO CIFRAS

0,31	**≈ 0**	**+0,08**	**6 de 34**
QWK con solo la edad, el sexo y la temporada de inscripción; el azar obtiene −0,01	ganancia de QWK al agregar las 33 variables físicas; sin evidencia de mejora	ganancia de QWK con sueño, funcionamiento global y horas de internet, en 25 de 25 particiones	casos severos con una serie de actigrafía utilizable

La etapa en un minuto

La pregunta	¿En qué medida los indicadores de actividad y aptitud física, junto con variables demográficas básicas, permiten estimar la severidad del uso problemático de internet (PIU), medida mediante el SII, en niños y adolescentes del Healthy Brain Network?
Esta etapa	Análisis exploratorio de los datos (objetivo 1), modelo de referencia frente a dos clasificadores sin información y primeras pruebas de las hipótesis H1 a H4 con dos configuraciones fijas (primera parte del objetivo 2).
Los datos	2.736 participantes con SII registrado, de 3.960; 34 casos severos; 823 participantes con una serie de actigrafía utilizable.
Lo que mostró el EDA	La asociación de las variables físicas con el SII se atenúa hasta valores cercanos a cero al controlar por la edad y el sexo. La de las horas de internet, el sueño y la actividad medida con actigrafía se mantiene después de ese control.
Resultados obtenidos	La edad, el sexo y la temporada de inscripción ya estiman el SII mejor que el azar (QWK ≈ 0,31): **H1 se sostiene**. En los experimentos iniciales, las variables físicas, incluida la actigrafía, no producen una mejora detectable del QWK: **no se obtuvo evidencia de mejora para H2 ni para H3**, un resultado preliminar. Las variables complementarias sí lo mejoran, hasta un QWK ≈ 0,39: **H4 se sostiene**.
Para la fase 3	Con un QWK casi igual, las dos configuraciones tratan el nivel severo de forma opuesta: el QWK por sí solo no basta para elegir un modelo de tamizaje.
Este reporte	Presenta resultados. De la metodología solo documenta los cambios que surgieron del análisis exploratorio; el resto se encuentra en la formulación [1].

Palabras clave: análisis exploratorio, actigrafía, clasificación ordinal, modelo de referencia, uso problemático de internet.

Glosario rápido de esta entrega

ENMO	Intensidad del movimiento registrada por el acelerómetro: norma del vector de aceleración menos la gravedad, truncada en cero.	**Serie utilizable**	Serie de actigrafía con al menos cuatro días de diez o más horas de uso de la pulsera.
Correlación parcial	Correlación entre un predictor y el SII después de eliminar la parte que explican la edad y el sexo.	**τ de Kendall**	Medida de asociación ordinal basada en pares de participantes ordenados en el mismo sentido o en sentido contrario.
Indicador de ausencia	Variable que vale 1 cuando el participante no tiene ningún dato de un instrumento.	**Prueba de permutación**	Repite el entrenamiento con el SII reordenado al azar para obtener el QWK que se esperaría sin relación con los predictores.
Prueba t corregida	Prueba t pareada de Nadeau y Bengio, que corrige la dependencia entre particiones que comparten participantes.	**Ajuste de Holm**	Corrección de los valores p cuando se hacen varias pruebas a la vez, para no acumular falsos positivos.
Intervalo de Wilson	Intervalo de confianza para una proporción, adecuado con muestras pequeñas, como los 34 casos severos.	**Precision**	Proporción de los participantes asignados a un nivel que realmente pertenecen a él.
Tasa de subestimación	Proporción de participantes con SII moderado o severo a los que se asigna un nivel inferior al real; incluye a los severos asignados a moderado.	**Recall del tamizaje**	Proporción de participantes moderados o severos a los que se asigna moderado o severo, es decir, que serían remitidos a valoración.

1 Qué trae esta entrega

Introducción y cambios respecto a la formulación

1.1 Introducción

EN POCAS PALABRAS

Esta entrega aporta resultados: qué mostraron los datos, cuánto estima el modelo de referencia y qué dicen las primeras pruebas de las hipótesis.

El proyecto busca determinar en qué medida los indicadores de actividad y aptitud física, junto con variables demográficas básicas, permiten estimar el nivel de severidad del PIU en niños y adolescentes del Healthy Brain Network [2], [3]. Este reporte corresponde a la segunda etapa y presenta los tres resultados que anticipa la sección 3.2 de la formulación [1]:

1. el **análisis exploratorio** del objetivo 1: cobertura de cada grupo de variables, patrón de los valores faltantes, comparación entre participantes con y sin SII y decisiones de tratamiento (sección 2);
2. el **desempeño del modelo de referencia** frente a los dos clasificadores sin información (secciones 3.1 y 3.2);
3. las **primeras pruebas de las hipótesis H1 a H4** con las dos configuraciones de los experimentos iniciales (secciones 3.2 a 3.6).

La formulación de referencia es la versión 3 de la Entrega 1, actualizada con la retroalimentación del profesor (sección 4.3). Allí se describe la metodología completa —esquema de validación cruzada anidada, métricas y pruebas estadísticas—, que aquí no se repite: este reporte remite a sus secciones y solo documenta los cambios que surgieron del análisis exploratorio (sección 1.2).

DÓNDE ESTÁ TODO

El código, los cuadernos y las figuras están en el repositorio público del proyecto [4]: github.com/juanestebancg2806/piu-severity-prediction. Los resultados provienen de dos cuadernos: **01_eda.ipynb** (análisis exploratorio) y **02_experimentos_iniciales.ipynb** (modelo de referencia y experimentos). Debajo de cada tabla y figura se indica la sección del cuaderno de la que proviene.

Privacidad. Los datos corresponden en su mayoría a menores de edad. Este reporte solo presenta cifras agregadas, nunca registros de participantes.

1.2 Cambios respecto a la formulación

EN POCAS PALABRAS

Diez decisiones del análisis exploratorio ajustan la formulación. Ninguna variable se eligió por su asociación con el SII.

La Tabla 1 reúne los únicos cambios metodológicos de esta etapa, con su motivo y la sección del cuaderno 01_eda.ipynb donde se justifican.

Tabla 1. Cambios respecto a la formulación que surgieron del análisis exploratorio

Cambio	Motivo	Sección del EDA
Se incorpora la **actigrafía** al grupo físico con tres variables: ENMO diurno en uso [5], ENMO nocturno en uso y horas de uso por día	Es la medida objetiva de la actividad física. Su cobertura (30,1 %) es comparable a la de la fuerza de agarre y no depende de la edad	9

Cambio	Motivo	Sección del EDA
Una serie es **utilizable** si tiene al menos 4 días con 10 o más horas de uso [6]: hay 823 series utilizables de 996	Con menos uso, los resúmenes no representan la actividad habitual	9
Se activa el conjunto **principal sin actigrafía** y, con él, la prueba de H3	La formulación lo condicionaba a que se incorporara la actigrafía	9
Se excluyen la **resistencia cardiorrespiratoria** (3 variables) y la **circunferencia de cintura**	Cobertura baja: la resistencia solo se aplica entre 6 y 12 años, y la cintura falta en el 82,3 % de los participantes	4
Se **fusionan PAQ-A y PAQ-C** en una sola variable	Son dos versiones del mismo cuestionario, para edades distintas y en la misma escala de 1 a 5	4
Se excluyen las **temporadas de cada instrumento**	Solo indican si el instrumento estaba programado, información que ya aportan los indicadores de ausencia	4
Se usa **un indicador de ausencia por instrumento**, no por variable	Las variables de un mismo instrumento faltan juntas	4
Se amplían las **reglas de limpieza**: se anula el registro completo de bioimpedancia si tiene un valor imposible (166 registros) y se recortan las pruebas de FitnessGram al máximo del protocolo [7] (584 valores)	La formulación solo mencionaba los valores nulos o negativos. Un valor imposible en la bioimpedancia indica que falló la medición completa; con la anulación, su cobertura baja de 66,3 % a 60,2 %	5
Se excluyen **7 variables calculadas a partir de otras**: tasa metabólica basal, agua corporal total, tejido blando magro, masa seca magra, IMC de la bioimpedancia, gasto energético diario y puntaje bruto del SDS	Son combinaciones exactas de otras variables o su relación con ellas es casi determinista	7
Se excluye el **contenido mineral óseo**	Decisión de calidad, no de identidad aritmética: en la mayoría de los registros es cerca del 6 % de la masa libre de grasa, pero el 21,8 % se aparta de ese patrón sin explicación	7

Las reglas exactas de limpieza y de resumen de la actigrafía están en el Anexo A. Fuente: 01_eda.ipynb, secciones 4, 5, 7, 9 y 10.

CRITERIO DE SELECCIÓN

Todos los cambios se basan en la **cobertura**, la **plausibilidad** y la **redundancia** entre predictores. Ninguna variable se eligió por su asociación con el SII: esa relación se analizó solo de forma descriptiva (sección 2.5), y cualquier selección que dependa del SII ocurre dentro de la validación cruzada.

Tamaño final de los conjuntos de variables

Con estos cambios, los cuatro conjuntos de la formulación quedan así. Están anidados y se evalúan sobre los mismos 2.736 participantes y las mismas particiones, de modo que cada hipótesis compara dos conjuntos que difieren en un solo bloque de variables.

Referencia	Principal sin actigrafía	Principal	Complementario
3	**33**	**36**	**39**
Edad, sexo y temporada de inscripción.	Referencia + 30 variables físicas tabulares.	Referencia + 33 variables físicas, incluidas las 3 de actigrafía.	Principal + SDS (puntaje T), CGAS y horas de uso de internet.

Número de predictores de cada conjunto. Fuente: 01_eda.ipynb, sección 10; 02_experimentos_iniciales.ipynb, sección 1.

2 Lo que muestran los datos

Análisis exploratorio · objetivo específico 1

El análisis sigue el criterio de cumplimiento del objetivo 1 (Tabla 2 de la formulación [1]): población y variable objetivo, cobertura y faltantes, calidad de los datos, distribuciones y redundancia, relación con el SII y actigrafía. Cada subsección cierra con las decisiones que tomó.

2.1 Población y variable objetivo

EN POCAS PALABRAS

Se analizan los 2.736 participantes con SII. Quienes no lo tienen muestran diferencias reducidas en edad media y proporción de mujeres, pero completaron muchos menos instrumentos.

3.960
participantes en el conjunto de entrenamiento de la competencia

1.224
sin SII (30,9 %): ninguno tiene respuestas del PCIAT

2.736
con SII (69,1 %): la población de análisis

Tabla 2. Comparación entre participantes con y sin SII

Característica	Con SII (2.736)	Sin SII (1.224)
Edad media (años)	10,2	10,9
Mujeres (%)	36,4	39,1
Con medidas físicas (%)	94,2	41,3
Con escala de sueño, SDS (%)	92,4	6,7
Con funcionamiento global, CGAS (%)	85,6	6,5
Con horas de uso de internet (%)	97,0	52,9

Fuente: 01_eda.ipynb, sección 3.

Las diferencias descriptivas en edad media y proporción de mujeres son reducidas, aunque estos resúmenes no descartan diferencias en las distribuciones. La diferencia en los instrumentos completados, en cambio, es marcada: la ausencia del SII refleja una selección por participación en el protocolo. El análisis se restringe a los etiquetados, y el desempeño estimado corresponde a ellos, no necesariamente a todos los participantes del conjunto original.

POBLACIÓN

Como en la formulación [1], se usa la denominación «niños y adolescentes», que corresponde a la mayoría de los participantes. La población de análisis incluye, sin embargo, a 84 participantes de 18 a 22 años (3,1 %), entre ellos 4 de los 34 casos severos, y todos los resultados de este reporte corresponden al rango completo de 5 a 22 años. Si el equipo decide restringir el alcance, la fase 3 incluirá un análisis de sensibilidad sin ese grupo.

Distribución del SII y desbalance

Tabla 3. Distribución del SII en los 2.736 participantes etiquetados

Nivel de SII	Participantes	%	Peso de clase	Casos por partición externa de evaluación
Ninguno	1.594	58,3	0,43	318 o 319
Leve	730	26,7	0,94	146

Nivel de SII	Participantes	%	Peso de clase	Casos por partición externa de evaluación
Moderado	378	13,8	1,81	75 o 76
Severo	34	1,2	20,12	6 o 7

Peso de clase: n / (4 × n del nivel), calculado aquí sobre todos los etiquetados con fines descriptivos; en el modelado se recalcula en cada partición de entrenamiento. Fuente: 01_eda.ipynb, sección 3; 02_experimentos_iniciales.ipynb, sección 2.

Con la ponderación inversamente proporcional a la frecuencia, un caso severo pesa en el entrenamiento unas 47 veces más que un participante sin PIU. Aun así, cada partición externa de evaluación contiene solo 6 o 7 casos severos, lo que condiciona la estabilidad de las métricas de ese nivel (sección 3.5).

Por sexo y edad

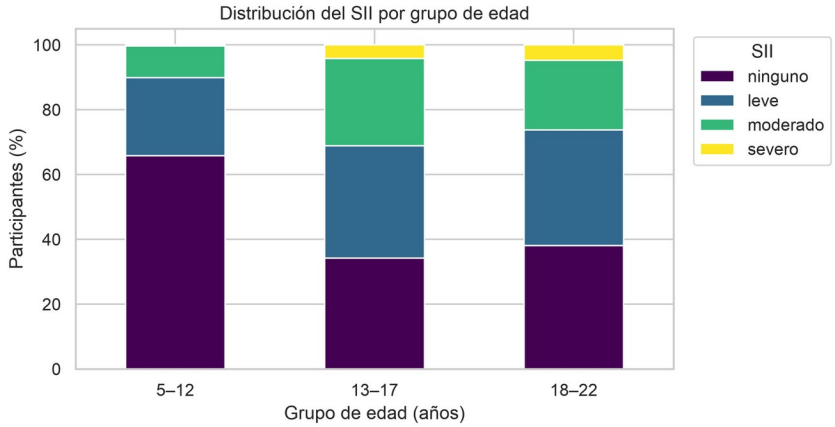


Figura 1. Distribución del SII por grupo de edad. La proporción de los niveles moderado y severo aumenta de forma marcada de la infancia a la adolescencia. Fuente: 01_eda.ipynb, sección 3.

Tabla 4. Proporción de PIU moderado o severo por subgrupo

Subgrupo	Participantes	Moderado o severo (%)	Casos severos
Mujeres	997	11,0	8
Hombres	1.739	17,4	26
5 a 12 años	2.070	10,1	6
13 a 17 años	582	31,1	24
18 a 22 años	84	26,2	4

Fuente: 01_eda.ipynb, sección 3.

La proporción de PIU moderado o severo es mayor en hombres que en mujeres y se triplica de la infancia a la adolescencia. El grupo de 18 a 22 años tiene solo 84 participantes, por lo que su valor no permite afirmar una tendencia en ese tramo. Al cruzar sexo y edad, las celdas del nivel severo tienen entre 1 y 19 casos; por eso, el análisis de errores por subgrupo de la fase 3 comparará los sexos y los grupos de edad por separado.

Calidad de la variable objetivo

- **Consistencia.** En todos los participantes, el SII coincide con el nivel que corresponde a su puntaje total del PCIAT según los puntos de corte: es una discretización directa de ese puntaje.
- **Ítems sin responder.** 65 participantes (2,4 %) tienen al menos un ítem faltante, y en 52 de ellos falta uno solo. Los ítems faltantes se contabilizan como cero en el puntaje total.

- **Posible subestimación.** En 17 participantes, el nivel podría ser mayor si los ítems faltantes hubieran recibido el puntaje máximo. Se conservan con el SII registrado, porque reconstruir las respuestas requeriría supuestos sin respaldo; son una fuente de ruido que tiende a subestimar la severidad.

Fuente: 01_eda.ipynb, sección 3.

2.2 Cobertura y patrón de los valores faltantes

> **EN POCAS PALABRAS**
> Los datos faltan por instrumento completo, no por variable, y varios instrumentos dependen de la edad del participante.

La Tabla 5 actualiza la Tabla 3 de la formulación [1]: compara la cobertura reportada allí, calculada sobre los datos originales, con la cobertura final sobre el conjunto analítico, después de la depuración y las exclusiones.

Tabla 5. Cobertura de cada instrumento en los participantes etiquetados: formulación frente a cobertura final

Instrumento	Grupo	Variables	Formulación	Final	Motivo del cambio
Datos demográficos	Demográfico	3	100 %	100 %	Sin cambio
Medidas antropométricas y signos vitales	Físico	6	94,2 %	92,6 %	Medidas inválidas tratadas como faltantes (sección 2.3)
Aptitud física (FitnessGram)	Físico	14	70,2 %	70,2 %	Sin cambio
Resistencia cardiorrespiratoria	Físico	0	26,7 %	Excluida	Cobertura baja y dependiente de la edad
Composición corporal (bioimpedancia)	Físico	9	66,3 %	60,2 %	Anulación de registros con valores imposibles
Actividad física autorreportada (PAQ)	Físico	1	65,9 %	65,3 %	Totales fuera del rango de 1 a 5
Actigrafía (series utilizables)	Físico	3	No incluida	30,1 %	Incorporada (sección 2.6)
Alteraciones del sueño (SDS)	Complementario	1	92,4 %	92,3 %	Se conserva solo el puntaje T; dos participantes tenían solo el bruto
Funcionamiento global (CGAS)	Complementario	1	85,6 %	85,6 %	Sin cambio
Horas diarias de uso de computador e internet	Complementario	1	97,0 %	97,0 %	Sin cambio

Cobertura: proporción de participantes etiquetados con al menos una variable del instrumento. Dentro de FitnessGram, la fuerza de agarre solo está disponible en el 31,7 %. Fuente: 01_eda.ipynb, secciones 4 y 10.

- **Faltan por bloques.** Quien tiene un dato de un instrumento casi siempre los tiene todos. Hay 79 combinaciones distintas de instrumentos: las 10 más frecuentes agrupan al 71,8 % de los participantes, y solo el 12,6 % tiene los ocho instrumentos.
- **Dos excepciones dentro de un instrumento.** La circunferencia de cintura falta en el 82,3 % de los participantes, sin un patrón claro por edad; la fuerza de agarre falta en cerca del 68 %, porque no se aplica antes de los 10 años.
- **Instrumentos que dependen de la edad** (Figura 2): la resistencia solo tiene datos entre 6 y 12 años, con un máximo del 45 %; el PAQ-C, entre 7 y 14; el PAQ-A, entre 13 y 18; y FitnessGram casi no tiene datos después de los 18.
- **Temporadas de instrumento.** Ningún participante tiene datos de un instrumento sin su temporada, pero muchos tienen la temporada sin datos (727 en FitnessGram): la temporada solo indica si el instrumento estaba programado.

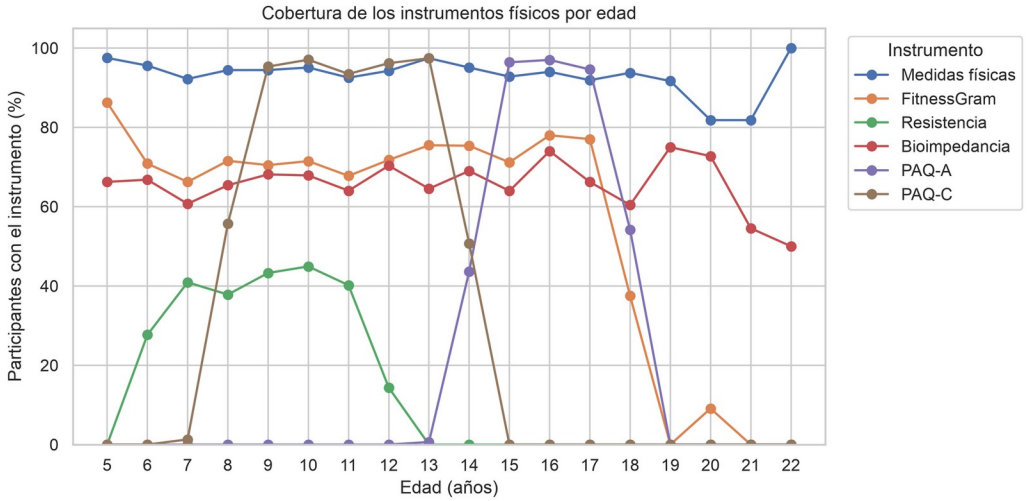


Figura 2. Cobertura de los instrumentos físicos por edad. La resistencia y las dos versiones del PAQ solo se aplican en ciertas edades. Fuente: 01_eda.ipynb, sección 4.

IMPLICACIÓN PARA EL MODELADO

Como la ausencia depende de la edad, los faltantes no son completamente aleatorios. Un indicador de ausencia como «no tiene resistencia» reflejaría en buena parte la edad, que ya está en todos los conjuntos; por eso, el aporte de los indicadores de ausencia debe interpretarse con cautela.

2.3 Calidad de los datos

EN POCAS PALABRAS

2.763 valores imposibles se tratan como faltantes. Casi todos provienen de 166 registros de bioimpedancia que fallaron por completo.

Las reglas usan criterios externos a los datos —el rango de la escala, el máximo del protocolo y límites fisiológicos amplios—, no su distribución ni el SII. Por eso se aplican antes de la validación cruzada sin introducir fuga de información. En total afectan a 257 participantes. Los umbrales exactos están en el Anexo A.

Tabla 6. Valores inválidos por instrumento

Instrumento	Participantes con al menos un valor inválido	Detalle
Bioimpedancia	166	Registro completo anulado (ver Tabla 7)
Medidas físicas	72	Peso (52 valores), presión diastólica (11), IMC (10), presión sistólica (4) y frecuencia cardiaca (4)
PAQ-C y PAQ-A	16	Puntajes menores que 1, fuera de la escala del cuestionario
FitnessGram	4	Fuerza de agarre igual a 0 o mayor que 100 kg
SDS	4	Puntajes brutos menores que 26
CGAS	0	—

Fuente: 01_eda.ipynb, sección 5.

Registros de bioimpedancia

En la bioimpedancia, todas las variables provienen de una misma medición y varias se calculan a partir de otras: un valor imposible indica que falló la medición completa. Depurar valor por valor dejaba inconsistencias evidentes, que desaparecen al anular el registro completo:

Tabla 7. Consistencia de la bioimpedancia según la forma de depurar

Indicador	Depuración valor por valor	Depuración por registro
Participantes con masa libre de grasa mayor que su peso	31	0
Masa libre de grasa máxima (libras)	8.799	186
Agua corporal total máxima (libras)	5.691	138
Tasa metabólica basal máxima (kcal por día)	3.988	2.291

Se anulan 166 de 1.813 registros (9,2 %). Fuente: 01_eda.ipynb, sección 5.

Máximos del protocolo de FitnessGram y valores atípicos

El protocolo de FitnessGram registra algunas pruebas solo hasta un tope [7]: 75 repeticiones en abdominales y flexiones de brazos, y 12 pulgadas en flexibilidad y levantamiento de tronco. Superarlo no es imposible, así que esos valores se recortan al máximo en lugar de eliminarse: 227 en flexibilidad derecha (11,9 %), 207 en flexibilidad izquierda (10,8 %), 144 en levantamiento de tronco (7,5 %) y 6 en abdominales (0,3 %). Tratarlos como inválidos habría eliminado 584 mediciones reales.

Después de depurar, en ninguna variable los valores a más de tres rangos intercuartílicos de los cuartiles superan el 0,83 % de los registros. Se conservan porque son posibles. Además, el IMC registrado coincide exactamente con el calculado a partir de la estatura y el peso en los 2.517 participantes con los tres datos.

Fuente: 01_eda.ipynb, sección 5.

2.4 Distribuciones y redundancia

EN POCAS PALABRAS

Muchas variables son asimétricas y varias son copias aritméticas de otras: las primeras se transforman y las segundas se excluyen.

Forma de las distribuciones

De las 32 variables numéricas, 19 tienen una asimetría mayor que 1 en valor absoluto, todas con cola hacia la derecha: los conteos de FitnessGram, las masas de bioimpedancia, el peso, el IMC y las presiones arteriales. Un logaritmo fijo corrige esas colas, pero empeora las pruebas que se acumulan en el máximo del protocolo: la asimetría de la flexibilidad pasa de −0,9 a −3,0. Por eso, en los modelos sensibles a la escala se usa la transformación de Yeo-Johnson [8], que se ajusta a cada variable dentro de cada partición de entrenamiento, como prevé la formulación.

También hay efectos de piso y de techo: un tercio de los participantes no completa ninguna flexión de brazos, y entre el 18 % y el 25 % queda en el máximo de flexibilidad o de levantamiento de tronco, en parte por el recorte. Las variables categóricas no tienen categorías tan escasas que requieran agruparse.

Bloques de variables redundantes

Un agrupamiento jerárquico sobre la correlación de Spearman identifica cuatro bloques de predictores redundantes ($|\rho| \geq 0{,}9$). La correlación de Pearson y la información mutua coinciden en todos ellos (Figura 3).

Tabla 8. Bloques de variables redundantes

Bloque	Variables	Contenido	$\lvert\rho\rvert$ medio
Tamaño corporal	9	Estatura, peso, masa libre de grasa, tejido blando magro, agua corporal total, intracelular y extracelular, masa muscular esquelética y tasa metabólica basal	0,94
Adiposidad	4	IMC de las medidas físicas y de la bioimpedancia, índice de masa grasa y porcentaje de grasa corporal	0,94
SDS	2	Puntaje bruto y puntaje T	1,00
Fuerza de agarre	2	Mano dominante y no dominante	0,92

Fuente: 01_eda.ipynb, sección 7.

Dentro de esos bloques, siete variables no solo se parecen a otras: se calculan a partir de ellas, y por eso se excluyen (Tabla 9). El contenido mineral óseo se excluye por un motivo distinto, de calidad (ver después de la tabla). Las demás se conservan aunque estén correlacionadas, porque son mediciones distintas; la regularización de la regresión logística atiende la colinealidad que permanece.

Tabla 9. Variables excluidas por calcularse a partir de otras

Variable excluida	Relación con otras variables	Se cumple en
Agua corporal total	Agua intracelular + extracelular	100 %
IMC de la bioimpedancia	Índice de masa libre de grasa + índice de masa grasa	100 %
Tejido blando magro	Masa libre de grasa − contenido mineral óseo	100 %
Masa seca magra	Masa libre de grasa − agua corporal total	100 %
Tasa metabólica basal	Recta exacta de la masa libre de grasa (diferencia máxima de 0,009 kcal)	100 %
Gasto energético diario	Tasa metabólica basal × un factor fijo por nivel de actividad y sexo	98 % a 100 %
Puntaje bruto del SDS	Correspondencia uno a uno con el puntaje T, que se conserva	57 de 57 puntajes

Fuente: 01_eda.ipynb, sección 7.

Contenido mineral óseo. En la mayoría de los registros equivale a cerca del 6 % de la masa libre de grasa (razón mediana de 0,0607), pero el 21,8 % de los registros (359 participantes) se aparta más de un 30 % de esa razón, sin una explicación en los datos. No es una copia aritmética de otra variable: se excluye como una decisión de calidad, porque no aporta información propia donde sigue el patrón y es dudoso donde no lo sigue. Su efecto puede evaluarse en la fase 3 con un análisis de sensibilidad.

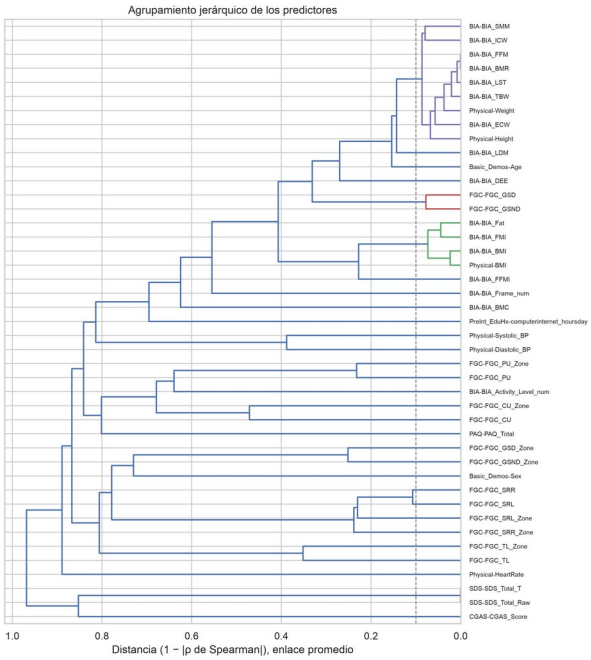


Figura 3. Agrupamiento jerárquico de los predictores con la distancia 1 − |ρ de Spearman|. La línea discontinua marca el umbral de redundancia (|ρ| ≥ 0,9). Fuente: 01_eda.ipynb, sección 7.

2.5 Relación de los predictores con el SII

EN POCAS PALABRAS

Es el hallazgo central del análisis: la asociación de las variables físicas con el SII se atenúa hasta casi cero al controlar por la edad y el sexo; la de las horas de internet y el sueño se mantiene.

UN ANÁLISIS SOLO DESCRIPTIVO

Esta relación se analizó para describir los datos y contrastar las hipótesis. **No se usó para seleccionar variables**: los conjuntos conservan todas las variables definidas por cobertura, plausibilidad y redundancia.

De los 35 predictores evaluados, 30 tienen una asociación de Kendall con el SII que se mantiene significativa tras el ajuste de Benjamini-Hochberg [9], pero todas son débiles o moderadas: la mayor es la de la edad (τ = 0,31). Como la edad se asocia a la vez con el SII (sección 2.1) y con el crecimiento —diez variables físicas tienen una correlación de al menos 0,7 con ella—, cada asociación se recalculó con dos controles que dan resultados similares (Tabla 10): la correlación parcial, que controla por la edad y el sexo, y el τ dentro de cada año de edad, que controla solo por la edad.

Tabla 10. Asociación con el SII, marginal y controlando por la edad y el sexo

Grupo	Variable	ρ marginal	ρ parcial (edad y sexo)	τ marginal	τ dentro de cada año de edad
Físico	Estatura	0,38	0,07	0,30	0,06
Físico	Masa libre de grasa	0,37	0,06	0,29	0,06
Físico	Peso	0,36	0,07	0,28	0,06
Físico	Abdominales	0,28	0,08	0,23	0,04
Físico	IMC	0,24	0,05	0,19	0,04
Complementario	Horas de uso de internet	0,34	0,21	0,30	0,19

Grupo	Variable	ρ marginal	ρ parcial (edad y sexo)	τ marginal	τ dentro de cada año de edad
Complementario	SDS (puntaje T)	0,23	0,24	0,18	0,19
Complementario	CGAS	−0,07	−0,06	−0,06	−0,06
Demográfico	Sexo	−0,10	−0,13	−0,09	−0,12

ρ: correlación de Spearman; la parcial elimina de los rangos del predictor y del SII la parte que explican linealmente los rangos de la edad y el sexo. τ dentro de cada año: promedio ponderado del τ de Kendall calculado en cada año de edad con al menos 30 participantes. Fuente: 01_eda.ipynb, sección 8.

- **Grupo físico.** Ninguna variable física supera 0,08 en valor absoluto en la correlación parcial ni en el τ dentro de cada año de edad. La estatura, por ejemplo, pasa de ρ = 0,38 a 0,07. El patrón es coherente con que tanto estas variables como el SII aumentan con la edad, y está en línea con el antecedente de la misma población, donde la actividad física y el IMC no se asociaron con el PIU una vez ajustados los factores de confusión [10].
- **Grupo complementario.** Las horas de uso de internet y el SDS conservan una asociación de alrededor de 0,2 con ese control. De los 19 predictores con un τ marginal de al menos 0,1 en valor absoluto, son los únicos dos que conservan ese nivel dentro de cada año de edad.
- **Grupo demográfico.** La asociación del sexo se fortalece ligeramente al controlar por la edad (τ de −0,09 a −0,12): dentro de una misma edad, los hombres presentan niveles de SII más altos. La temporada de inscripción no se asocia con el SII (V de Cramér = 0,035; p = 0,35).

ALCANCE DE ESTOS CONTROLES

La correlación parcial elimina solo la parte lineal de los rangos de la edad y el sexo, y el τ dentro de cada año de edad no controla por el sexo. Ninguno de los dos descarta relaciones no lineales, interacciones ni confusión residual. Por eso esta sección describe asociaciones; el aporte predictivo de las variables físicas se evalúa en los experimentos (sección 3.3).



Figura 4. Asociación de cada predictor con el SII: marginal (punto lleno) y controlando por la edad y el sexo (punto vacío). Azul: variables físicas; naranja: complementarias; gris: demográficas. Las variables físicas se acercan a cero; las complementarias, no. Fuente: 01_eda.ipynb, sección 8.

Controlar por grupos de edad amplios no basta: dentro del grupo de 5 a 12 años, la estatura mantiene un τ de 0,24, porque ese grupo abarca ocho años de crecimiento; dentro de cada año de edad, baja a 0,06. La Figura 5 muestra el mismo patrón: las diferencias entre grupos de edad son mucho mayores que las diferencias entre niveles de SII dentro de un mismo grupo.

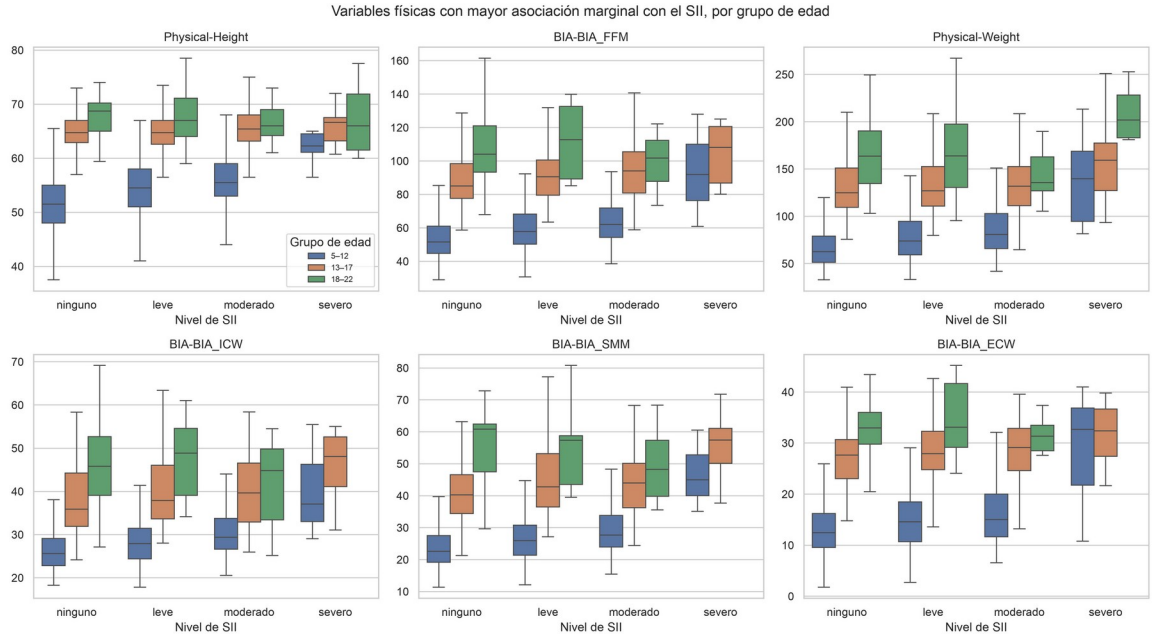


Figura 5. Las seis variables físicas con mayor asociación marginal con el SII, por nivel de SII y grupo de edad. En el nivel severo, las cajas se basan en 6, 24 y 4 participantes. Fuente: 01_eda.ipynb, sección 8.

2.6 Actigrafía

EN POCAS PALABRAS

La actigrafía es la única medida física cuya asociación con el SII se mantiene al controlar por la edad y el sexo, pero solo el 30 % de los participantes, y 6 de los 34 casos severos, tiene una serie utilizable.

996	823	34 días	6 de 34
etiquetados con una serie de actigrafía (36,4 %)	con una serie utilizable (30,1 %)	distancia típica entre la actigrafía y el PCIAT	casos severos con una serie utilizable

Los participantes con serie tienen un perfil similar al de los demás: edad media de 10,3 frente a 10,2 años, 34,6 % frente a 37,5 % de mujeres y la misma distribución del SII; la proporción con serie es parecida en los tres grupos de edad (entre 36,3 % y 40,5 %). Las series son largas —24 días en la mediana—, pero el uso efectivo es muy desigual (Figura 6): la mitad de los participantes casi no se quita la pulsera, y una cuarta parte la tiene quitada más de 9,2 horas por día. Con el criterio de al menos cuatro días con diez o más horas de uso, se descartan 173 series.

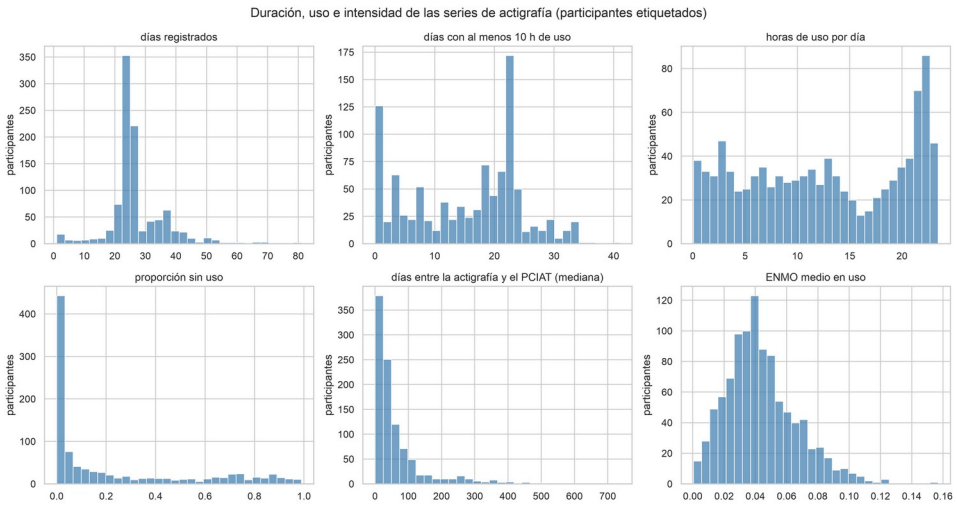


Figura 6. Duración, uso e intensidad de las 996 series de actigrafía de los participantes etiquetados. Fuente: 01_eda.ipynb, sección 9.

Tabla 11. Series de actigrafía por nivel de SII

Nivel de SII	Etiquetados	Con serie	Con serie utilizable	% con serie utilizable
Ninguno	1.594	583	491	30,8
Leve	730	266	221	30,3
Moderado	378	137	105	27,8
Severo	34	10	6	17,6

Fuente: 01_eda.ipynb, sección 9.

Tabla 12. Asociación de las variables de actigrafía con el SII en las 823 series utilizables

Variable	Sin control (ρ)	Controlando edad y sexo	Controlando edad, sexo y horas de uso	Dentro de cada año de edad (τ)
ENMO diurno en uso (8:00 a 21:00)	−0,31	−0,17	−0,17	−0,12
ENMO medio en uso	−0,28	−0,15	−0,16	−0,10

Variable	Sin control (ρ)	Controlando edad y sexo	Controlando edad, sexo y horas de uso	Dentro de cada año de edad (τ)
ENMO nocturno en uso (0:00 a 6:00)	−0,03	−0,02	−0,04	−0,01
Horas de uso por día	−0,03	−0,05	—	—

Un signo negativo indica que a mayor movimiento, menor severidad. Fuente: 01_eda.ipynb, sección 9.

El ENMO diurno se asocia negativamente con el SII: los participantes con mayor severidad se mueven menos durante el día. La asociación baja de −0,31 a −0,17 al controlar por la edad, porque la intensidad disminuye con ella, pero se mantiene con los tres controles, también al controlar por las horas de uso de la pulsera, a diferencia de las variables físicas tabulares. El movimiento nocturno y las horas de uso no se asocian con el SII. Se incorporan tres variables, elegidas por criterios de medición: el ENMO diurno, el ENMO nocturno y las horas de uso por día; el ENMO medio se descarta porque mezcla actividad y descanso según cuándo se use la pulsera.

DOS LIMITACIONES DE LA ACTIGRAFÍA

Pocos casos severos. Solo 6 de los 34 casos severos tienen una serie utilizable (17,6 %, frente a cerca del 30 % en los demás niveles).

Desfase temporal. La actigrafía no se registró al mismo tiempo que el PCIAT: la distancia típica es de 34 días, y en el 5 % de los participantes supera los 260 días, de modo que la actividad medida no siempre corresponde al periodo en que se evaluó el SII.

3 Modelo de referencia y primeras pruebas

Experimentos iniciales · primera parte del objetivo específico 2

Según la sección 2.4 de la formulación [1], dos configuraciones fijas —una **regresión logística** multinomial y un **gradient boosting**, ambas en la formulación multiclase y con pesos por nivel— se entrenaron con los cuatro conjuntos sobre las mismas 25 particiones externas. Así, las diferencias entre conjuntos reflejan la información que aportan y no el algoritmo. Ambas se implementaron con scikit-learn [11], con una búsqueda reducida de hiperparámetros en la validación interna. Los resultados se reportan como media ± desviación estándar entre las cinco repeticiones.

3.1 Verificación del flujo de evaluación

EN POCAS PALABRAS

Antes de interpretar modelos se comprobó que las particiones y la evaluación funcionan: los controles sin información obtienen el QWK esperado.

25
particiones externas (5 × 5), de 547 o 548 participantes cada una

6 o 7
casos severos en cada partición externa de evaluación

9 o 10
casos severos en cada partición interna, usada para elegir hiperparámetros

- **Particiones correctas.** En cada repetición, cada participante se evalúa exactamente una vez, y ninguna partición comparte participantes entre entrenamiento y evaluación.
- **Estratificación prácticamente exacta.** En todos los niveles, el número de casos varía como máximo en uno entre particiones.
- **Preprocesamiento sin fuga.** Se ajusta solo con la partición de entrenamiento. La regresión logística no recibe valores faltantes (imputación y hasta 8 indicadores de ausencia, según el conjunto); gradient boosting recibe entre el 27,8 % y el 31,1 % de celdas faltantes, que maneja de forma nativa.

Tabla 13. Desempeño de los dos clasificadores sin información

Métrica	Clase mayoritaria	Aleatorio estratificado
QWK	0,000 ± 0,000	−0,010 ± 0,022
QWK por partición (mínimo y máximo)	0,000 y 0,000	−0,078 y 0,082
Recall severo	0,000 ± 0,000	0,006 ± 0,013
Subestimación moderado o severo	1,000 ± 0,000	0,874 ± 0,022

Fuente: 02_experimentos_iniciales.ipynb, secciones 2 a 4.

Los dos controles producen los valores esperados para un modelo sin información. El aleatorio fija además el margen del azar: sin ninguna información, el QWK de una sola partición varió entre −0,078 y 0,082. Por eso las comparaciones se basan en las 25 diferencias pareadas y no en particiones aisladas.

3.2 Modelo de referencia y prueba de H1

EN POCAS PALABRAS

Con solo la edad, el sexo y la temporada de inscripción, el QWK llega a 0,31, muy por encima del azar: H1 se sostiene.

Tabla 14. Modelo de referencia frente al clasificador aleatorio

Métrica	Aleatorio estratificado	Regresión logística	Gradient boosting
QWK	**−0,010 ± 0,022**	**0,311 ± 0,004**	**0,302 ± 0,005**
Recall ninguno	0,586 ± 0,011	0,646 ± 0,005	0,643 ± 0,009
Recall leve	0,273 ± 0,021	0,208 ± 0,013	0,235 ± 0,011
Recall moderado	0,123 ± 0,025	0,238 ± 0,011	0,211 ± 0,024
Recall severo	0,006 ± 0,013	0,582 ± 0,048	0,324 ± 0,072
Subestimación moderado o severo	0,874 ± 0,022	0,387 ± 0,005	0,466 ± 0,010

Fuente: 02_experimentos_iniciales.ipynb, sección 5.

Las dos configuraciones alcanzan un QWK de alrededor de 0,30: con tres variables, un modelo más flexible no aporta sobre uno lineal. La ponderación de las clases desplaza las asignaciones hacia los niveles altos —la subestimación de los casos moderados o severos baja de 0,874 a 0,387 con la regresión logística—, a costa del nivel leve, cuyo recall queda por debajo del aleatorio.

Prueba de H1

En la prueba de permutación [12], el entrenamiento de la regresión logística se repitió 200 veces con el SII reordenado al azar. El QWK observado en la primera repetición fue de 0,310; con etiquetas permutadas, la media fue de 0,000, el percentil 95 de 0,016 y el máximo de 0,036. Ninguna permutación se acercó al valor observado: el valor p es 0,005, el mínimo posible con 200 permutaciones (1/201).

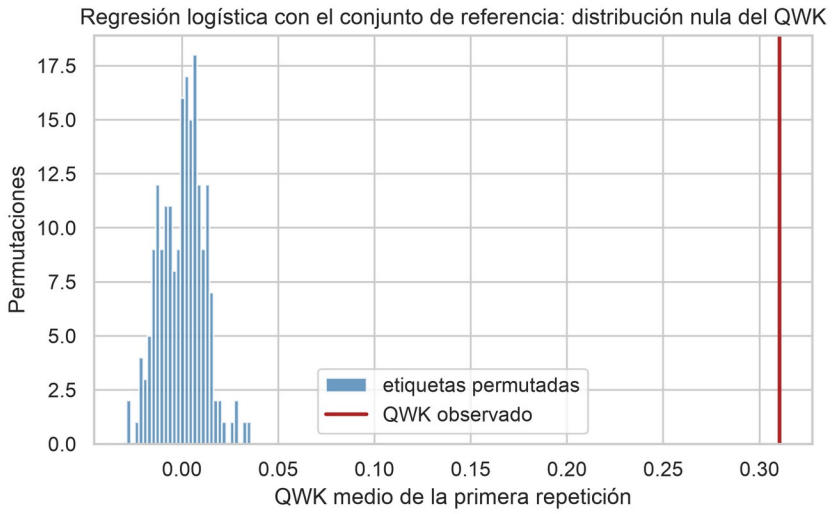


Figura 7. Distribución del QWK con etiquetas permutadas (200 permutaciones) y QWK observado de la regresión logística con el conjunto de referencia. Fuente: 02_experimentos_iniciales.ipynb, sección 5.

H1 SE SOSTIENE

La edad y el sexo contienen información sobre la severidad del PIU. Un QWK de alrededor de 0,31 es el desempeño que deben superar los conjuntos con variables físicas para aportar información adicional.

3.3 Experimentos iniciales: H2, H3 y H4

EN POCAS PALABRAS

Agregar las variables físicas no produce una mejora detectable del QWK; agregar las complementarias lo sube en 0,08 en todas las particiones.

Tabla 15. QWK de cada conjunto con las dos configuraciones

Conjunto	Bloque que agrega	Regresión logística	Gradient boosting
Referencia	—	0,311 ± 0,004	0,302 ± 0,005
Principal sin actigrafía	30 variables físicas tabulares	0,308 ± 0,003	0,310 ± 0,011
Principal	Las 3 variables de actigrafía	0,308 ± 0,005	0,315 ± 0,007
Complementario	SDS, CGAS y horas de internet	0,384 ± 0,011	0,393 ± 0,008

Fuente: 02_experimentos_iniciales.ipynb, sección 6.

Los tres primeros conjuntos obtienen prácticamente el mismo QWK, alrededor de 0,31, con ambas configuraciones. Solo el conjunto complementario se separa, con alrededor de 0,39. La Tabla 16 pone a prueba cada diferencia de forma pareada, partición por partición.

Tabla 16. Pruebas pareadas de H2, H3 y H4

Hipótesis	Configuración	Diferencia media de QWK	Particiones con mejora	Valor p ajustado	Resultado
H2: principal − referencia	Regresión logística	−0,003 ± 0,023	11 de 25	0,998	Sin evidencia de mejora
	Gradient boosting	0,014 ± 0,031	17 de 25	0,822	Sin evidencia de mejora
H3: principal − principal sin actigrafía	Regresión logística	0,000 ± 0,013	11 de 25	0,998	Sin evidencia de mejora
	Gradient boosting	0,006 ± 0,023	15 de 25	0,981	Sin evidencia de mejora
H4: complementario − principal	Regresión logística	0,076 ± 0,027	25 de 25	< 0,001	**Se sostiene**
	Gradient boosting	0,078 ± 0,034	25 de 25	< 0,001	**Se sostiene**

Diferencia media ± desviación estándar de las 25 diferencias pareadas. Valor p unilateral de la prueba t corregida de Nadeau y Bengio [13], ajustado con el método de Holm [14] sobre las seis pruebas. Si no hubiera efecto, se esperarían 12 o 13 particiones con mejora. Fuente: 02_experimentos_iniciales.ipynb, sección 6.

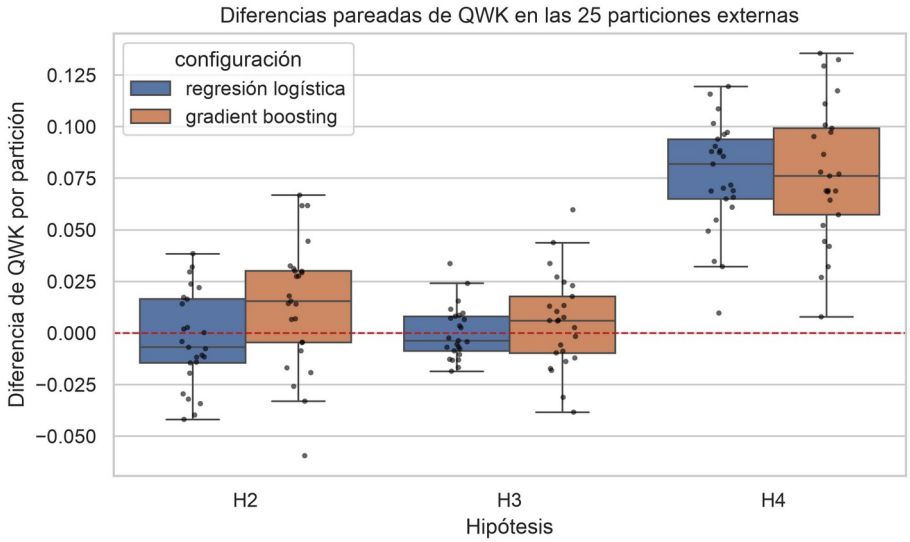


Figura 8. Diferencias pareadas de QWK en las 25 particiones externas. En H2 y H3, las cajas quedan a ambos lados de cero; en H4, todas las diferencias son positivas. Fuente: 02_experimentos_iniciales.ipynb, sección 6.

- **H2: sin evidencia de mejora.** Con la regresión logística, la diferencia es prácticamente cero y el conjunto principal gana en menos de la mitad de las particiones. Con gradient boosting es positiva (0,014) y gana en 17 de 25, pero la prueba pareada no la distingue de cero (valor p ajustado de 0,822).
- **H3: sin evidencia de mejora.** Las diferencias al retirar la actigrafía son de 0,000 y 0,006, sin consistencia entre particiones (valores p ajustados de 0,998 y 0,981).
- **H4 se sostiene.** Las variables complementarias mejoran el QWK en 0,076 y 0,078, alrededor de un 25 % sobre el conjunto principal, en las 25 particiones con ambas configuraciones.

UN RESULTADO PRELIMINAR

Con dos configuraciones fijas y la formulación multiclase, **no se obtuvo evidencia estadísticamente significativa de mejora** para H2 ni para H3. Un valor p no significativo no demuestra que las variables físicas o la actigrafía carezcan de aporte: concluir que su aporte es despreciable requeriría definir una diferencia mínima relevante y un análisis de equivalencia. La búsqueda completa de la fase 3 —con otros algoritmos, las formulaciones ordinales y la estrategia de faltantes como hiperparámetro— podría extraer más información de estas variables.

3.4 Desempeño por nivel de severidad

EN POCAS PALABRAS

Con un QWK casi igual, las dos configuraciones tratan el nivel severo de forma opuesta. El QWK por sí solo no basta para evaluar un tamizaje.

Tabla 17. Desempeño por nivel de severidad

Métrica	Regresión logística Referencia	Regresión logística Principal	Regresión logística Complementario	Gradient boosting Referencia	Gradient boosting Principal	Gradient boosting Complementario
Recall ninguno	0,646	0,613	0,653	0,643	0,655	0,682
Recall leve	0,208	0,253	0,282	0,235	0,281	0,329
Recall moderado	0,238	0,329	0,380	0,211	0,353	0,386
Recall severo	**0,582**	**0,594**	**0,571**	**0,324**	**0,153**	**0,171**
Subestimación moderado o severo	0,387	0,427	0,421	0,466	0,608	0,574
Participantes asignados a severo	514	370	254	472	88	65
Precision severo	0,039	0,055	0,076	0,023	0,059	0,090
Recall del tamizaje (moderados o severos remitidos)	0,638	0,600	0,608	0,575	0,433	0,471
Severos remitidos (asignados a moderado o severo)	0,894	0,918	0,924	0,812	0,653	0,718

Medias de las cinco repeticiones. El conjunto principal sin actigrafía se omite porque sus valores son prácticamente iguales a los del principal. Fuente: 02_experimentos_iniciales.ipynb, sección 7.

Regresión logística

Mantiene un **recall severo cercano a 0,58** en todos los conjuntos.

Lo logra asignando el nivel severo a muchos participantes: **514** con la referencia, con una **precision de 0,039**.

El 38 % de los moderados y el 11 % de los participantes sin PIU reciben el nivel severo.

Gradient boosting

Con la referencia se comporta de forma parecida, con menor recall severo (0,324).

Con variables físicas **casi deja de asignar el nivel severo**: 88 participantes con el principal.

Su recall severo cae a **0,153**: el **84,7 %** de los casos severos recibe un nivel inferior.

El QWK no refleja esta diferencia porque el nivel severo agrupa solo 34 de los 2.736 participantes y pesa poco en la métrica. Los casos severos subestimados casi nunca se asignan al nivel ninguno (como máximo 2 de 34 en promedio): la mayoría queda en el nivel moderado. En el escenario de tamizaje de la formulación, que remite a quien recibe un nivel moderado o severo, la regresión logística identifica entre el 88 % y el 92 % de los casos severos, y gradient boosting con variables físicas, el 65 %.

La tasa de subestimación y el recall del tamizaje no son complementarios. La subestimación cuenta como error a un caso severo asignado a moderado, que en el tamizaje sí se remitiría: con la regresión logística y la referencia, el 36,2 % de los moderados o severos no se remitiría (1 − 0,638), y el resto, hasta la subestimación de 0,387, son severos asignados a moderado. Las conclusiones sobre remisión se basan en el recall del tamizaje. La especificidad y la proporción de participantes remitidos, que miden el costo de un recall alto, se reportarán en la fase 3 con el modelo seleccionado, como prevé el escenario de tamizaje de la formulación.

Además, las variables físicas **redistribuyen los errores en lugar de reducirlos**: el recall moderado sube de 0,21–0,24 a 0,33–0,35, a costa del nivel ninguno en la regresión logística y del severo en gradient boosting. Las variables complementarias mejoran sobre todo los niveles intermedios y la precision de todos los niveles. El nivel leve es el más difícil: entre el 32 % y el 39 % de los participantes leves se asignan al nivel ninguno.

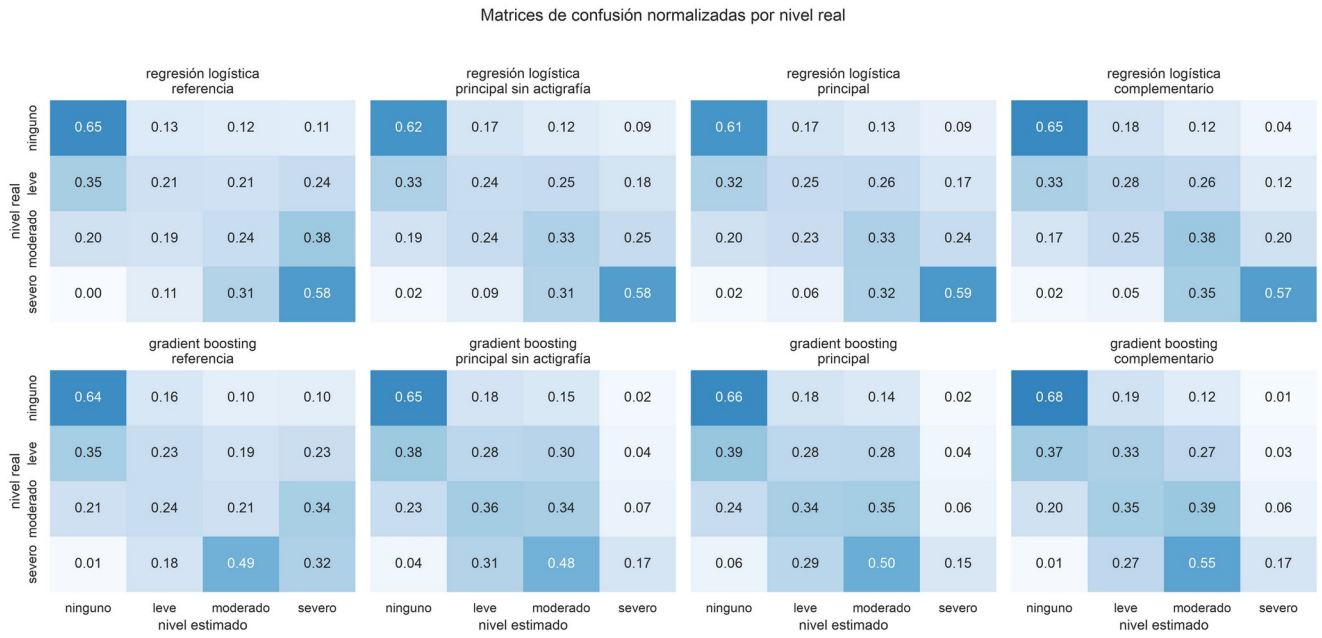


Figura 9. Matrices de confusión normalizadas por nivel real y promediadas en las cinco repeticiones. La diagonal es el recall de cada nivel. Fuente: 02_experimentos_iniciales.ipynb, sección 7.

3.5 Incertidumbre del nivel severo

EN POCAS PALABRAS

El recall severo es estable entre repeticiones, así que el plan para el caso inestable no se activa. Aun así, con 34 casos sus intervalos de confianza son amplios.

La sección 2.5 de la formulación [1] considera inestable el recall severo si su desviación estándar entre las cinco repeticiones supera 0,10, es decir, unos tres casos, y pide reportarlo con su intervalo de confianza del 95 % por el método de Wilson [15]. La Tabla 18 aplica ambos criterios.

Tabla 18. Recall del nivel severo: intervalo de confianza y criterio de inestabilidad

Configuración	Conjunto	Recall severo	Casos identificados (de 34)	IC del 95 % aproximado (Wilson)	Desviación entre repeticiones	¿Inestable?
Regresión logística	Referencia	0,582	19,8	0,417–0,731	0,048	No
	Principal sin actigrafía	0,576	19,6	0,411–0,726	0,049	No
	Principal	0,594	20,2	0,428–0,741	0,038	No
	Complementario	0,571	19,4	0,406–0,721	0,068	No
Gradient boosting	Referencia	0,324	11,0	0,191–0,492	0,072	No
	Principal sin actigrafía	0,171	5,8	0,080–0,328	0,025	No
	Principal	0,153	5,2	0,068–0,308	0,025	No
	Complementario	0,171	5,8	0,080–0,328	0,025	No

Recall calculado sobre los 34 casos severos de cada repetición; recall y casos identificados: media de las cinco repeticiones. El intervalo se calculó con esa media y n = 34, como aproximación al intervalo de una repetición: no suma las cinco repeticiones como si fueran casos nuevos, pero el promedio de los mismos participantes no es una proporción binomial en sentido estricto. Criterio de inestabilidad: desviación mayor que 0,10. Fuente: 02_experimentos_iniciales.ipynb, sección 7.

- **Estable.** La desviación entre repeticiones va de 0,025 a 0,072, por debajo del criterio de 0,10 en los ocho casos: el plan que la formulación prevé para el caso inestable no se activa.
- **Pero incierto.** La estabilidad frente a la partición no elimina la incertidumbre de estimar una proporción con 34 casos: los intervalos aproximados tienen una amplitud de entre 0,24 y 0,32. Describen esa incertidumbre, no la variabilidad del entrenamiento. En la fase 3, el modelo seleccionado se reportará con el intervalo de Wilson sobre los aciertos enteros de cada repetición o con un remuestreo por participante.
- **Una diferencia descriptiva grande.** Con el conjunto principal, la regresión logística identifica en promedio unos 20 de los 34 casos severos y gradient boosting unos 5. Como ambas se evalúan sobre los mismos casos, el solapamiento de sus intervalos individuales no sirve para decidir: la diferencia debe estimarse con una comparación pareada (por ejemplo, la prueba de McNemar sobre las predicciones de cada repetición), que queda para la fase 3.
- **Una caída por confirmar.** El recall severo de gradient boosting baja de 0,324 con la referencia a 0,153 con el principal. Tampoco se probó de forma pareada, así que se reporta como descriptiva y no se atribuye todavía a las variables físicas.

3.6 Relación con el análisis exploratorio

EN POCAS PALABRAS

Los experimentos confirman en términos predictivos lo que el análisis exploratorio mostró de forma descriptiva, con una excepción: la actigrafía.

Tabla 19. Hipótesis: lo que anticipaba el análisis exploratorio y lo que mostraron los experimentos

Hipótesis	Lo que anticipaba el EDA	Lo que mostraron los experimentos	¿Coincide?
H1: la referencia supera al azar	La edad y el sexo se asocian con el SII, también al controlar uno por el otro (sección 2.5)	QWK de 0,31 frente a un máximo de 0,036 en 200 permutaciones	Sí
H2: principal > referencia	La asociación de las variables físicas tabulares se atenúa hasta casi cero al controlar por la edad y el sexo	Diferencias de −0,003 y 0,014, que no se distinguen de cero	Sí
H3: principal > principal sin actigrafía	El ENMO diurno conserva su asociación con el SII después del control (−0,17)	Retirar la actigrafía no cambia el QWK (0,000 y 0,006)	No
H4: complementario > principal	Las horas de internet y el SDS conservan una asociación de alrededor de 0,2	Mejora de 0,08 en las 25 particiones	Sí

Fuente: 01_eda.ipynb, secciones 8 y 9; 02_experimentos_iniciales.ipynb, secciones 5 y 6.

La discrepancia de H3 merece discutirse. Hay dos explicaciones posibles, ninguna contrastada todavía. La primera es la **cobertura**: solo el 30 % de los participantes tiene una serie utilizable, y la cobertura no es uniforme, porque en el nivel severo baja al 17,6 % (6 de 34). Una asociación moderada en ese subconjunto pesaría poco frente a la variación del QWK en los 2.736 participantes. La segunda es el **desfase** de semanas o meses entre la actigrafía y el PCIAT. Un análisis restringido a los 823 participantes con serie utilizable, que compare la referencia con y sin actigrafía sobre los mismos participantes y particiones, ayudaría a distinguirlas; sus conclusiones se limitarían a esa subpoblación, que es una selección por disponibilidad de la serie (sección 4.1).

4 Qué sigue

Implicaciones para la fase 3, estado del plan y respuesta a la retroalimentación

4.1 Implicaciones para la fase 3

EN POCAS PALABRAS

Los experimentos iniciales dejan abiertas cinco cuestiones para la búsqueda completa de modelos.

Tabla 20. Implicaciones de los resultados para la fase 3

Aspecto	Qué mostró esta etapa	Implicación para la fase 3
H2 y H3	Sin evidencia de mejora con dos configuraciones fijas y la formulación multiclase	Volver a evaluarlas con la configuración seleccionada; si se quiere afirmar que el aporte es despreciable, definir antes una diferencia mínima relevante
Selección del modelo	Configuraciones con un QWK similar difieren mucho en la detección de los casos moderados y severos	El desempate por la tasa de subestimación de la regla de selección será determinante
Desbalance	La ponderación produce muchas asignaciones erróneas al nivel severo en la regresión logística y no sostiene su recall en gradient boosting	Ajustar la ponderación de las clases y los umbrales de la formulación de regresión dentro de la búsqueda
Actigrafía	Conserva su asociación con el SII, pero solo cubre al 30 % de los participantes y al 17,6 % de los severos; la cobertura y el desfase son explicaciones posibles, no demostradas	Análisis restringido a los 823 participantes con serie utilizable, comparando referencia y actigrafía sobre los mismos participantes y particiones, con conclusiones limitadas a esa subpoblación
Nivel severo	Recall estable, pero con intervalos aproximados de entre 0,24 y 0,32 de amplitud; las diferencias entre configuraciones solo se describieron	Calcular el intervalo de Wilson sobre aciertos enteros o con remuestreo por participante, y comparar configuraciones con una prueba pareada

Fuente: 02_experimentos_iniciales.ipynb, sección 8.

LO QUE ESTOS RESULTADOS NO PERMITEN CONCLUIR

- Que «las variables físicas no sirven»: en los experimentos iniciales no mejoran el QWK frente a la edad y el sexo, y el resultado es preliminar.
- Que una configuración sea mejor que la otra: son dos configuraciones fijas, y la comparación entre algoritmos corresponde a la fase 3.
- Relaciones causales: las asociaciones son descriptivas y el SII proviene del reporte de los padres, con ruido de medición que limita el desempeño alcanzable.

4.2 Estado del plan

EN POCAS PALABRAS

Las actividades de la fase 2 están completas, cada bloque con un revisor distinto de su responsable, y el criterio de cumplimiento del objetivo 1 queda verificado.

Tabla 21. Actividades de la fase 2 (Tabla 5 de la formulación)

Actividad	Fechas	Responsable	Revisor	Estado
Análisis exploratorio y tratamiento de los datos (objetivo 1)	20 oct – 6 nov	Juan David Martínez	Daniel Velasco	Completada: 01_eda.ipynb

Actividad	Fechas	Responsable	Revisor	Estado
Flujo de validación, modelo de referencia y experimentos iniciales (objetivo 2)	27 oct – 9 nov	Juan Esteban Cardona	Katherin Camargo	Completada: 02_experimentos_iniciales.ipynb
Redacción de la Entrega 2	10 – 13 nov	Equipo	Equipo	Este documento
Revisión final y Entrega 2	14 nov	Equipo	Equipo	PDF en deliverables/deliverable-2 y tag deliverable-2

Fuente: formulación [1], Tabla 5, y repositorio del proyecto [4].

Tabla 22. Verificación de los criterios de cumplimiento (Tabla 2 de la formulación)

Objetivo	Elemento del criterio de cumplimiento	Dónde se cumple en este reporte
1	Conjunto de datos analítico documentado	Sección 1.2 y Tabla 5; 01_eda.ipynb, sección 10
1	Cobertura de cada grupo de variables	Tabla 5 y Figura 2
1	Distribución del SII	Tablas 3 y 4; Figura 1
1	Comparación entre participantes con y sin SII	Tabla 2
1	Decisiones de tratamiento justificadas	Tabla 1 y secciones 2.2 a 2.6
2 (avance)	QWK de modelos con variables físicas frente al de un modelo de referencia demográfico	Tablas 14, 15 y 16, en la formulación multiclase; las formulaciones ordinales corresponden a la fase 3

4.3 Respuesta a la retroalimentación de la Entrega 1

> **EN POCAS PALABRAS**
> Los cinco puntos del profesor se atendieron en la formulación v3 y se aplican en este reporte.

Tabla 23. Respuesta a la retroalimentación de la Entrega 1

Punto del profesor	Qué se hizo	Dónde
1. El objetivo 5 es el menos medible	Se definió su criterio: al menos tres recomendaciones, como mínimo una por cada uno de los objetivos 2, 3 y 4, y al menos una acción de mejora, en una tabla que vincula cada una con su resultado y su limitación. Este reporte deja identificadas las primeras candidatas (Tabla 20)	Formulación v3, sección 1.6 y Tabla 2
2. La Entrega 2 debe aportar resultados	Este reporte presenta el EDA, el modelo de referencia y las primeras pruebas de hipótesis; de la metodología solo documenta los cambios surgidos del EDA	Todo el reporte; cambios en la Tabla 1
3. Concentración de carga en Juan Esteban Cardona	Cada bloque del cronograma tiene un revisor distinto de su responsable; los revisores de sus bloques siguen el código desde el inicio	Formulación v3, Tabla 5; Tabla 21 de este reporte
4. Faltan el DOI de [26] y la URL de [29]	Se agregaron. En este reporte, todas las referencias tienen DOI o URL	Formulación v3 y lista de referencias de este reporte
5. Plan si el recall severo resulta inestable	Se definieron el criterio de inestabilidad (desviación mayor que 0,10) y el intervalo de Wilson, y se aplicaron: el recall severo es estable, pero con intervalos amplios	Formulación v3, sección 2.5; sección 3.5 de este reporte

Referencias

[1] K. A. Camargo Cetina, J. E. Cardona García, J. D. Martínez Legarda y D. Velasco López, "Evaluación de indicadores de actividad y aptitud física para estimar la severidad del uso problemático de internet en niños y adolescentes mediante aprendizaje automático. Primera entrega (versión user friendly 3)," Maestría en Inteligencia Artificial Aplicada, Universidad Icesi, Cali, Colombia, 2026. [En línea]. Disponible: https://github.com/juanestebancg2806/piu-severity-prediction/tree/main/deliverables/deliverable-1

[2] Child Mind Institute y Kaggle, "Child Mind Institute — Problematic Internet Use," Kaggle, 2024. [En línea]. Disponible: https://www.kaggle.com/competitions/child-mind-institute-problematic-internet-use

[3] L. M. Alexander et al., "An open resource for transdiagnostic research in pediatric mental health and learning disorders," Scientific Data, vol. 4, art. 170181, 2017, doi: 10.1038/sdata.2017.181.

[4] K. A. Camargo Cetina, J. E. Cardona García, J. D. Martínez Legarda y D. Velasco López, "piu-severity-prediction," repositorio de GitHub, 2026. [En línea]. Disponible: https://github.com/juanestebancg2806/piu-severity-prediction

[5] V. T. van Hees et al., "Separating movement and gravity components in an acceleration signal and implications for the assessment of human daily physical activity," PLoS ONE, vol. 8, no. 4, e61691, 2013, doi: 10.1371/journal.pone.0061691.

[6] R. P. Troiano, D. Berrigan, K. W. Dodd, L. C. Mâsse, T. Tilert y M. McDowell, "Physical activity in the United States measured by accelerometer," Medicine & Science in Sports & Exercise, vol. 40, no. 1, pp. 181–188, 2008, doi: 10.1249/mss.0b013e31815a51b3.

[7] The Cooper Institute, FitnessGram Administration Manual: The Journey to MyHealthyZone, 5.ª ed. Champaign, IL, EE. UU.: Human Kinetics, 2017, ISBN: 978-1-4504-7046-9. [En línea]. Disponible: https://us.humankinetics.com/products/fitnessgram-administration-manual-5th-edition-with-web-resource

[8] I.-K. Yeo y R. A. Johnson, "A new family of power transformations to improve normality or symmetry," Biometrika, vol. 87, no. 4, pp. 954–959, 2000, doi: 10.1093/biomet/87.4.954.

[9] Y. Benjamini e Y. Hochberg, "Controlling the false discovery rate: A practical and powerful approach to multiple testing," Journal of the Royal Statistical Society: Series B (Methodological), vol. 57, no. 1, pp. 289–300, 1995, doi: 10.1111/j.2517-6161.1995.tb02031.x.

[10] A. Restrepo et al., "Problematic internet use in children and adolescents: associations with psychiatric disorders and impairment," BMC Psychiatry, vol. 20, art. 252, 2020, doi: 10.1186/s12888-020-02640-x.

[11] F. Pedregosa et al., "Scikit-learn: Machine learning in Python," Journal of Machine Learning Research, vol. 12, pp. 2825–2830, 2011. [En línea]. Disponible: https://jmlr.org/papers/v12/pedregosa11a.html

[12] M. Ojala y G. C. Garriga, "Permutation tests for studying classifier performance," Journal of Machine Learning Research, vol. 11, pp. 1833–1863, 2010. [En línea]. Disponible: https://jmlr.org/papers/v11/ojala10a.html

[13] C. Nadeau y Y. Bengio, "Inference for the generalization error," Machine Learning, vol. 52, no. 3, pp. 239–281, 2003, doi: 10.1023/A:1024068626366.

[14] S. Holm, "A simple sequentially rejective multiple test procedure," Scandinavian Journal of Statistics, vol. 6, no. 2, pp. 65–70, 1979. [En línea]. Disponible: https://www.jstor.org/stable/4615733

[15] E. B. Wilson, "Probable inference, the law of succession, and statistical inference," Journal of the American Statistical Association, vol. 22, no. 158, pp. 209–212, 1927, doi: 10.1080/01621459.1927.10502953.

Anexo A. Reglas exactas de preparación de los datos

Este anexo documenta los umbrales y las reglas de los cambios metodológicos de la Tabla 1, para que puedan reconstruirse desde el reporte. Están implementados en el paquete del proyecto (src/piu_severity/data/clean.py y src/piu_severity/features/actigraphy.py), en la versión del repositorio marcada con el tag deliverable-2 [4]. Las unidades son las del diccionario de datos: pulgadas para la estatura y libras para el peso y las masas de bioimpedancia.

Tabla A1. Reglas de depuración de valores inválidos y máximos del protocolo

Variable	Regla: el valor se trata como faltante si...	Criterio
Estatura	es menor que 30 o mayor que 84 pulgadas (76 a 213 cm)	Límite fisiológico amplio
Peso	es menor que 20 o mayor que 400 libras (9 a 181 kg)	Límite fisiológico amplio
IMC (medidas físicas y bioimpedancia)	es menor que 10 o mayor que 70	Límite fisiológico amplio
Presión diastólica	es menor que 30 o mayor que 130 mmHg	Límite fisiológico amplio
Presión sistólica	es menor que 60 o mayor que 220 mmHg	Límite fisiológico amplio
Presión arterial	la diastólica es mayor o igual que la sistólica (se anulan ambas)	Definición fisiológica
Frecuencia cardiaca	es menor que 40 o mayor que 200 latidos por minuto	Límite fisiológico amplio
Fuerza de agarre (ambas manos)	es menor o igual que 0 o mayor que 100 kg	Límite fisiológico amplio
Abdominales y flexiones de brazos	es negativo; los valores mayores que 75 repeticiones se recortan a 75	Máximo del protocolo [7]
Flexibilidad (ambos lados) y levantamiento de tronco	es negativo; los valores mayores que 12 pulgadas se recortan a 12	Máximo del protocolo [7]
Contenido mineral óseo	es menor o igual que 0 o mayor que 20 libras	Límite fisiológico amplio
Grasa corporal	es menor o igual que 0 % o mayor que 60 %	Límite fisiológico
Tasa metabólica basal	es menor que 500 o mayor que 4.000 kcal por día	Límite fisiológico amplio
Gasto energético diario	es menor que 500 o mayor que 8.000 kcal por día	Límite fisiológico amplio
Demás masas, agua corporal e índices de bioimpedancia	es menor o igual que 0	Definición de la medida
Registro completo de bioimpedancia	cualquiera de sus variables es inválida según las reglas anteriores: se anulan todas las variables del registro, salvo la temporada	Una misma medición del equipo
CGAS	es menor que 1 o mayor que 100	Rango de la escala
SDS (puntaje bruto)	es menor que 26 o mayor que 130	26 ítems calificados de 1 a 5
PAQ-A y PAQ-C	es menor que 1 o mayor que 5	Rango de la escala

Orden de aplicación: primero se recortan los máximos del protocolo y después se anulan los valores inválidos. Las reglas son fijas y no se ajustan con los datos. Fuente: src/piu_severity/data/clean.py; 01_eda.ipynb, sección 5.

Tabla A2. Resumen de las series de actigrafía

Elemento	Regla
Tiempo de uso	Un registro está en uso cuando su indicador de no uso (non-wear_flag) vale 0. El indicador viene con los datos de la competencia.
Día	Cada valor distinto del día relativo a la aplicación del PCIAT (relative_date_PCIAT).
Horas de uso de un día	Número de registros en uso del día × intervalo de muestreo (5 s en todas las series) / 3.600.
Días parciales	No se excluyen: el primer y el último día cuentan en el promedio de horas de uso, y solo cuentan como días válidos si alcanzan 10 horas de uso.

Elemento	Regla
Día válido y serie utilizable	Un día es válido con al menos 10 horas de uso; una serie es utilizable con al menos 4 días válidos. Sin serie utilizable, las tres variables quedan faltantes.
Horas de uso por día (variable)	Promedio de las horas de uso de todos los días registrados de la serie.
ENMO diurno en uso (variable)	Media del ENMO de los registros en uso con hora entre las 8:00 y las 21:00 (21:00 excluida).
ENMO nocturno en uso (variable)	Media del ENMO de los registros en uso con hora entre las 0:00 y las 6:00 (6:00 excluida). Queda faltante si no hay registros en uso en esa franja (11 series utilizables).
Distancia al PCIAT (descriptiva)	Valor absoluto de la mediana del día relativo al PCIAT. No se usa como predictor.

Fuente: src/piu_severity/features/actigraphy.py; 01_eda.ipynb, sección 9.